

Cronograma de Entregas

Sistema Multiagente Inteligente de Cobrança com LLM, RAG e Machine Learning

Gabriel Forster Rocha

Jul. a dez. de 2026 — Engenharia de Software, Católica de Santa Catarina

1. Cronograma de entregas

Cada encontro tem **uma entrega pequena, verificável e acumulativa** — código rodando, dado gerado, ou seção de texto escrita. A coluna *Artefato* é o que se mostra no encontro; a coluna *Texto* é o que avança no artigo, para que a redação não fique concentrada no fim.

Bloco I — Fundação: requisitos e dados (30/07 a 27/08)

#	Data	Entrega	Artefato mostrado	Texto
1	30/07	Definições. Escopo fechado, este cronograma, repositório organizado (article/, docs/, RFC compilando)	RFC em PDF + cronograma aprovado	Proposta de portfólio revisada
2	06/08	Requisitos e domínio. Fluxo atual de cobrança mapeado, 10 RF + 6 RNF consolidados, restrições legais (CDC, LGPD, PROCON: horário, frequência, consentimento de gravação) e baselines de comparação definidos	Documento de requisitos + tabela de restrições legais	Seção de metodologia (etapa i)
3	13/08	Dados brutos. Fontes identificadas (cadastro, faturas, histórico de atraso, acordos, resultado de cobranças), extração do ERP, anonimização LGPD, dicionário de dados. Meta: ≥ 5.000 documentos históricos	Dataset anonimizado + dicionário de dados	Descrição da base de dados
4	20/08	EDA e limpeza. Estatísticas descritivas, distribuição do alvo, desbalanceamento medido, missings/outliers tratados, gráficos (atraso, inadimplência por segmento, sazonalidade, heatmap de correlação)	Notebook de EDA + 4 gráficos	Análise exploratória
5	27/08	Features e splits. <i>Feature engineering</i> (dias médios de atraso, taxa histórica, frequência recente, valor relativo, tendência de pagamento), encoding, escala, split 70/15/15 estratificado respeitando ordem temporal (sem vazamento)	Pipeline de features versionado + 3 conjuntos	Justificativa das features

Bloco II — Módulo preditivo (03/09 a 17/09)

#	Data	Entrega	Artefato mostrado	Texto
6	03/09	Baseline. Regressão logística treinada na Tarefa 1 (propensão ao pagamento), métricas completas (acurácia, precisão, revocação, F1, AUC-ROC) + matriz de confusão	Tabela de métricas do baseline	Baseline preditivo
7	10/09	Modelos fortes, Tarefa 1. Random Forest e XGBoost/LightGBM com validação cruzada (k=5), <i>tuning</i> de hiperparâmetros e tratamento de desbalanceamento (SMOTE vs. <i>class weights</i>); modelo campeão escolhido	Comparativo de algoritmos + curvas ROC/PR	Resultados da Tarefa 1
8	17/09	Tarefa 2 + API. Modelo de previsão de inadimplência futura (documentos não vencidos) treinado e avaliado, interpretabilidade (<i>feature importance</i> + SHAP), modelo serializado e exposto por API de inferência que devolve o <i>ranking</i> de prioridade	P0ST /score respondendo + gráfico SHAP	Resultados da Tarefa 2 e interpretabilidade

Bloco III — Arquitetura e módulo responsivo (24/09 a 15/10)

#	Data	Entrega	Artefato mostrado	Texto
9	24/09	Arquitetura multiagente. Quatro camadas definidas, papéis dos três agentes, contrato de eventos, fila de mensagens e regra de prioridade (responsivo > proativo); esqueleto do orquestrador central rodando com agentes <i>stub</i>	Diagrama + orquestrador roteando evento de ponta a ponta	Seção de arquitetura
10	01/10	RAG. Ingestão (PDF/DOCX/CSV/TXT) de políticas, <i>scripts</i> de negociação, tabelas de parcelamento e FAQ; <i>chunking</i> (500-1000 tokens, <i>overlap</i> 50-100), <i>embeddings</i> , indexação vetorial e <i>retrieval</i> top-k avaliado por precisão/revocação	Consulta ao índice retornando trechos corretos	Pipeline RAG
11	08/10	Agente responsivo (texto). <i>System prompt</i> , classificação de intenção (consulta, 2ª via, negociação, contestação, confirmação de pagamento), resposta ancorada no RAG, critérios de escalação para humano	Conversa completa por texto, latência < 5 s medida	Módulo responsivo
12	15/10	Canal + áudio. Integração com WhatsApp Business API e transcrição de áudio (OGG/OPUS → STT), tratamento de erro (áudio inaudível, curto, <i>timeout</i>)	Áudio de WhatsApp respondido corretamente	Integração de voz (offline)

Bloco IV — Módulo ativo e telefonia (22/10 a 05/11)

#	Data	Entrega	Artefato mostrado	Texto
13	22/10	Detecção + regras. <i>Job</i> periódico de documentos vencidos, consumo do <i>ranking</i> preditivo para cobrança preventiva, motor de regras (horário permitido, frequência máxima, canal, <i>cooldown</i> , limite de tentativas)	Fila de cobrança populada com prioridade preditiva	Módulo ativo (parte 1)
14	29/10	Abordagem multicanal por texto. <i>Templates</i> por estágio de atraso (1-7, 8-30, 31-60, 60+ dias) personalizados por LLM, envio pelo WhatsApp, <i>tracking</i> de status (enviada/entregue/lida/respondida), respeito imediato a <i>opt-out</i> , transferência ao agente responsivo quando o cliente responde	Escalonamento progressivo executando em ambiente de teste	Módulo ativo (parte 2)
15	05/11	Chamada telefônica automatizada. Número outbound, <i>webhooks</i> , fluxo TTS de abertura → STT em tempo real → resposta → encerramento, aviso de gravação e registro completo da chamada	Chamada real gravada e transcrita	Integração de voz (tempo real)

Bloco V — Avaliação e fechamento (12/11 a 03/12)

#	Data	Entrega	Artefato mostrado	Texto
16	12/11	Testes e início do experimento. Testes unitários (parser, <i>features</i> , motor de regras, intenção, <i>templates</i>) com $\geq 80\%$ das funções críticas cobertas, testes de integração dos três fluxos e dos serviços externos; experimento controlado iniciado contra os dois baselines (manual e semiautomatizado sem ML)	Suíte de testes verde + experimento coletando dados	Protocolo experimental
17	19/11	Resultados consolidados. Métricas preditivas finais vs. baseline, qualidade do RAG (<i>retrieval</i> + fidelidade/completude/alucinação das respostas), indicadores operacionais (taxa de recuperação, tempo médio de resolução, custo por contato, ≥ 100 interações concorrentes), análise estatística	Tabelas e gráficos finais de resultados	Seção de resultados e discussão
18	26/11	Revisão final. Artigo completo revisado (resumo/abstract, referências, tabelas, figuras), limitações e trabalhos futuros, README de reprodução; ajuste dos pontos apontados pelo orientador	Artigo em PDF, versão candidata	Texto integral fechado
19	03/12	Trabalho finalizado. Versão final entregue, repositório com <i>tag</i> de entrega, apresentação/defesa preparada e ensaiada	PDF final + <i>slides</i> + demonstração	—

2. Relação com o cronograma do RFC

O RFC (Tabela 3) previa 24 semanas em 8 fases; este cronograma distribui as mesmas 8 fases nos 19 encontros, sobrepondo blocos que podem correr em paralelo (arquitetura durante o fim do módulo preditivo; voz sobre o módulo ativo) e reservando as três últimas semanas para avaliação, redação e defesa.

Fase do RFC	Encontros
1 — Requisitos e análise do domínio	30/07, 06/08
2 — Coleta e preparação de dados	13/08, 20/08, 27/08
3 — Módulo preditivo de ML	03/09, 10/09, 17/09
4 — Arquitetura multiagente	24/09
5 — Módulo responsivo (RAG + LLM)	01/10, 08/10, 15/10
6 — Módulo ativo/proativo	22/10, 29/10
7 — Integração de voz	15/10 (STT offline), 05/11 (telefonía)
8 — Testes, experimentos e avaliação	12/11, 19/11
Redação final e defesa	26/11, 03/12

3. Riscos e plano de contingência

Risco	Impacto	Contingência
Volume ou qualidade insuficiente dos dados históricos	Bloqueia as entregas 6–8	Antecipar a extração (13/08) e, se necessário, usar base pública de <i>credit scoring</i> para validar o pipeline, mantendo a base real apenas para o modelo final
Aprovação de <i>templates</i> na Meta / conta de telefonia	Atrasa 29/10 e 05/11	Iniciar cadastro já em 15/10; ambiente <i>sandbox</i> do provedor como plano B da demonstração
Latência das chamadas com STT em tempo real	Compromete a entrega 15	Reduzir o escopo da chamada para roteiro guiado (menos turnos livres) e registrar a limitação
Experimento operacional com amostra pequena	Enfraquece a entrega 17	Relatar tamanho de efeito e intervalo de confiança; complementar com métricas técnicas e comparação de custo por contato
Custo de APIs de LLM, STT/TTS e telefonia	Afeta 08/10 em diante	Cache de respostas, modelo menor para tarefas simples, Whisper local como alternativa

Escopo mínimo garantido (se algo precisar cair): os módulos responsivo e preditivo mais o fluxo proativo por texto são obrigatórios; a chamada telefônica em tempo real é a primeira candidata a virar prova de conceito reduzida, com a limitação documentada no artigo.
