Prévia: voz e console interno

Sistema Multiagente Inteligente de Cobrança com LLM, RAG e Machine Learning

Gabriel Forster Rocha · 06/11/2026 — pré-apresentação, parte 2

O que esta prévia mostra

Duas partes do sistema que ainda **não estão construídas** e que aqui aparecem como protótipos de tela, montados sobre o que **já existe e foi medido**:

Tela	O que é real	O que é protótipo	
1	**Chamada de voz** (entrega 15)	o áudio (sintetizado localmente pelo Piper), a transcrição pelo Whisper local, a intenção, a consulta à base, a regra de leitura de volta e todos os tempos medidos	a tela, o transporte WebRTC, a geração do texto do agente
2	**Console interno**	as probabilidades dos dois modelos publicados e o porquê de cada uma (SHAP) para os 1.167 clientes; a tabela de parcelamento e os limites de alçada	a tela, os nomes, os contadores operacionais do dia

Arquivos que acompanham este PDF:

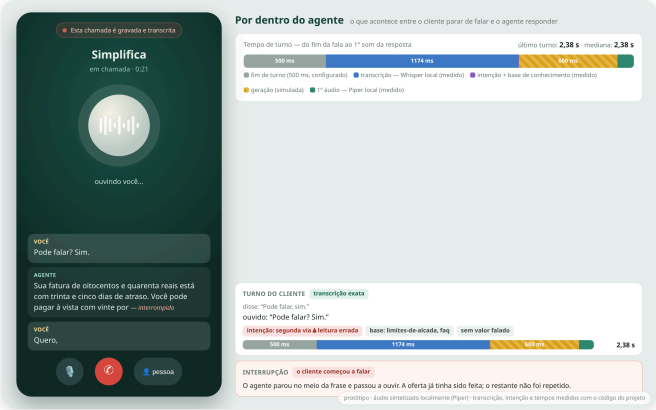
- `video/00-demo-voz-e-console.mp4` : as duas demonstrações com cartelas, 1 min 58 s, **com áudio**
- `video/02-chamada-de-voz.mp4` : a chamada completa, 69 s, com áudio
- `video/01-console.mp4` : o percurso pelo console, 40 s
- `img/` : todas as telas em alta resolução
- `mock/` : as páginas do protótipo, que abrem no navegador (`console.html` , `voz.html`)

1. A chamada de voz

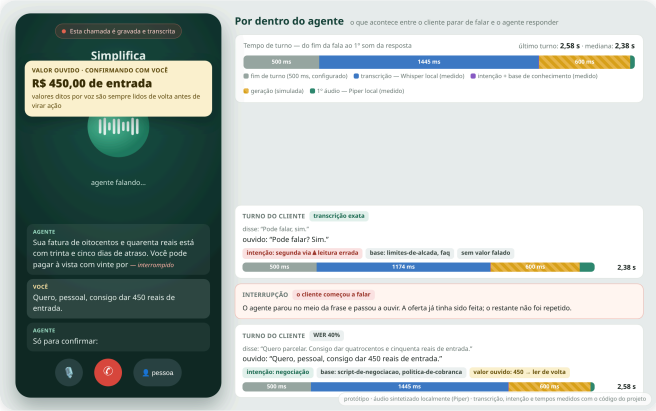
O cliente atende uma chamada no navegador. O aviso de gravação é a primeira frase e não pode ser pulado. Ao lado, o painel **Por dentro do agente** mostra, a cada turno, o que o sistema ouviu, o que entendeu, o que consultou e quanto tempo cada etapa levou.



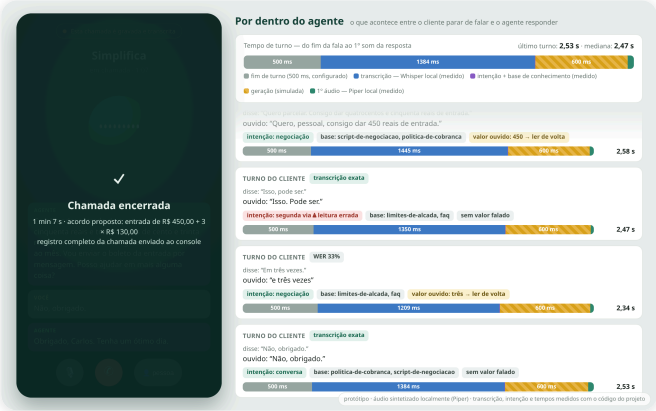
Abertura: o aviso de gravação vem antes de qualquer outra coisa.



Interrupção: o cliente começa a falar e o agente para no meio da frase.



Leitura de volta: um valor dito por voz nunca vira ação sem ser confirmado.



Fim da chamada: acordo proposto dentro da alçada, registro enviado ao console.

O roteiro. Carlos deve R$ 840,00 com 35 dias de atraso, o que o coloca na faixa de 31 a 60 dias da tabela: entrada mínima de 15%, até 10 parcelas, 20% de desconto à vista e juros de 1,5% ao mês. Ele oferece R$ 450,00 de entrada e o restante em 3 vezes de R$ 130,00: dentro da alçada automática (até 12 parcelas) e acima da parcela mínima de R$ 50,00.

O que cada turno custa

Medido nesta máquina (Ryzen 7 5700X3D, só CPU) com o código do projeto: o áudio do cliente foi sintetizado pelo Piper, transcrito pelo `WhisperTranscriber` (modelo `small`, int8), e o texto passou pelo classificador de intenção, pela resolução de intenção pelo contexto da conversa, pela busca na base e pela regra `needs_confirmation`.

O cliente disse	O Whisper ouviu	Intenção	Lê de volta?	STT	Turno
“Pode falar, sim.”	“Pode falar? Sim.”	segunda via ⚠	—	1.174 ms	2,38 s
“Quero parcelar. Consigo dar quatrocentos e cinquenta reais de entrada.”	“Quero, pessoal, consigo dar 450 reais de entrada.”	negociação	**450**	1.445 ms	2,58 s
“Isso, pode ser.”	“Isso. Pode ser.”	segunda via ⚠	—	1.350 ms	2,47 s
“Em três vezes.”	“e três vezes”	negociação	**três**	1.209 ms	2,34 s
“Não, obrigado.”	“Não, obrigado.”	conversa	—	1.384 ms	2,53 s

Tempo de turno (do fim da fala ao primeiro som da resposta), mediana **2,47 s**:

Etapa	Tempo	Origem
Detecção de fim de turno	500 ms	configurado (janela de silêncio), não medido
Transcrição (Whisper `small`, local)	**1.174–1.445 ms**	medido
Intenção + base de conhecimento	2,5–3,5 ms	medido
Geração do texto	600 ms	**simulado**: sem chave de LLM nesta máquina
Primeiro áudio da resposta (Piper, local)	21–101 ms	medido

O que a prévia revelou

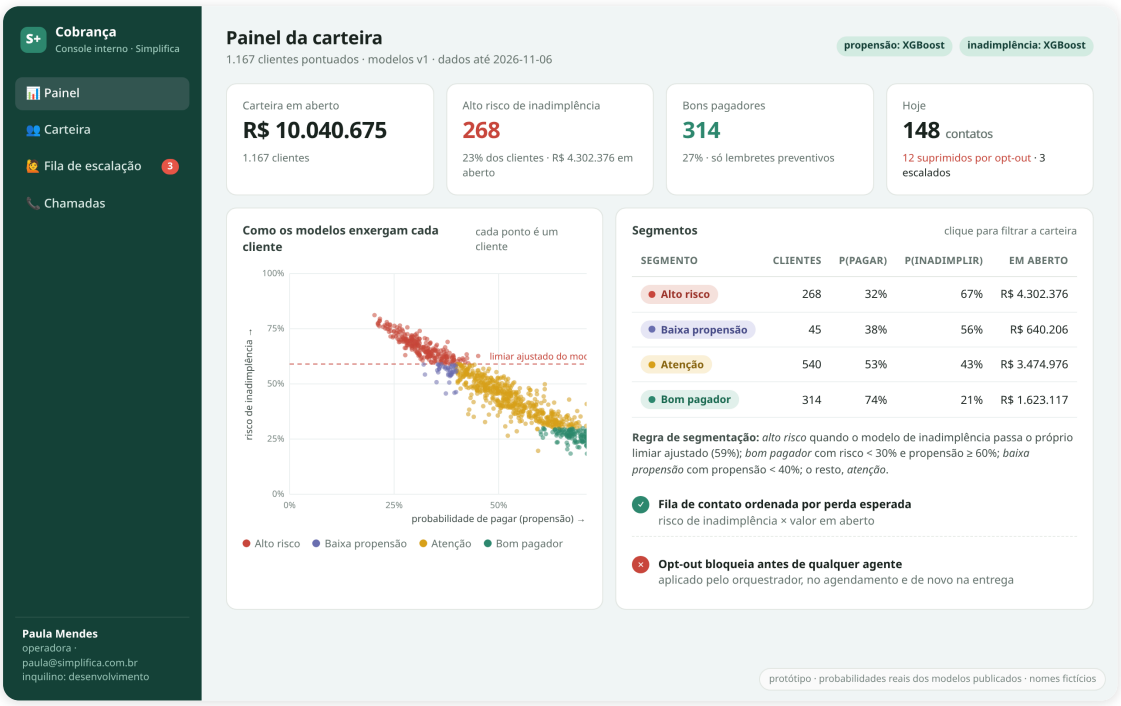
1. **A transcrição domina o tempo do turno.** A síntese de voz local é quase gratuita: o Piper produz o primeiro áudio em 21–101 ms e fala 38 vezes mais rápido que o tempo real. Já o Whisper leva cerca de 1,3 s por frase, na proporção de 0,5 s de processamento por segundo de fala. A primeira otimização a tentar é transcrever enquanto o cliente ainda fala, não trocar a voz.
2. **O erro de reconhecimento atingiu os valores, como a medição anterior previu.** “Quero parcelar” virou “Quero, pessoal” (40% de palavras erradas) e, mesmo assim, a intenção (*negociação*) e o valor (450) sobreviveram. Os dois valores falados na chamada dispararam a leitura de volta, e é por isso que ela existe.
3. **Uma lacuna real: a resposta a uma pergunta de sim/não.** “Pode falar, sim” e “Isso, pode ser” foram classificadas como *segunda via*. Uma palavra casou fracamente com uma frase-pista dessa intenção, com confiança de 0,076, acima do mínimo de 0,04. Assim o agente se considera seguro e nem consulta o contexto da conversa. No chat isso quase não aparece; na voz, onde toda leitura de volta

termina num “sim”, aparece em todo turno. **Correção para a entrega 15:** depois de uma leitura de volta, a próxima fala é tratada como confirmação (sim/não), não reclassificada.

4. **Um defeito encontrado no caminho:** com a versão 19 da biblioteca `av` instalada pelo `uv.lock`, a transcrição real pelo Whisper falha (`metadata_errors`). A CI não percebe porque usa o transcritor roteirizado. Fixar `av<19` resolve; as medições acima foram feitas com `av` 18.

2. O console interno: como os modelos enxergam cada cliente

Cada ponto do gráfico é um cliente real da base de demonstração. A posição vem das duas probabilidades que os modelos publicados calculam para ele: **propensão a pagar** (eixo horizontal) e **risco de inadimplência** (eixo vertical).



Painel da carteira: 1.167 clientes, R$ 10,0 milhões em aberto, divididos em quatro segmentos.

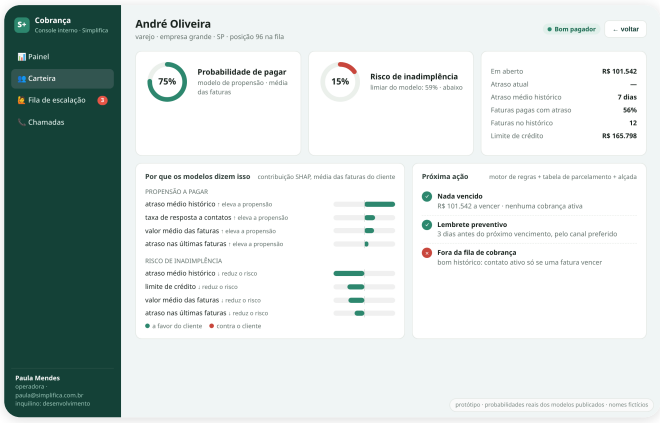
Segmento	Regra	Clientes	P(pagar)	P(inadimplir)	Atraso médio histórico	Faturas pagas com atraso
Alto risco	inadimplência ≥ limiar ajustado (59%)	268	32%	67%	178 dias	92%
Baixa propensão	propensão < 40%	45	38%	56%	113 dias	87%
Atenção	o restante	540	53%	43%	41 dias	55%
Bom pagador	risco < 30% e propensão ≥ 60%	314	74%	21%	7 dias	34%

Os segmentos não foram desenhados à mão sobre o histórico: saem das duas probabilidades. O histórico de cada segmento (as duas últimas colunas) mostra que eles separam comportamentos de fato diferentes. A probabilidade de inadimplência não está calibrada (o modelo foi treinado com peso extra na classe rara), por isso o corte usa o **limiar ajustado do próprio modelo**, não 50%.

Um cliente de cada lado



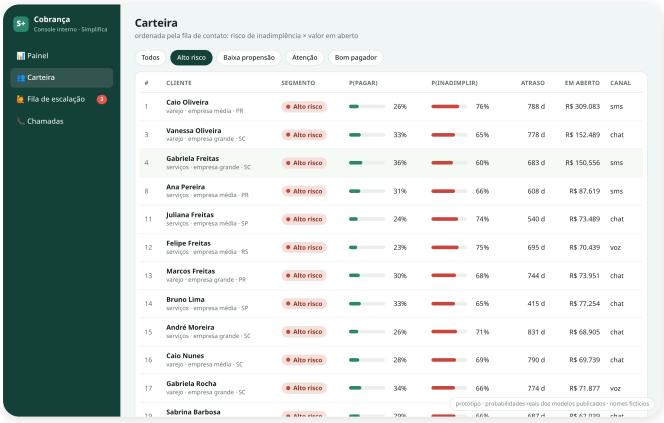
Alto risco: 683 dias de atraso, todas as 7 faturas do histórico pagas com atraso. A faixa da tabela permitiria 18 parcelas e 40% de desconto, mas a alçada automática para em 12x e 20%: acima disso, uma pessoa aprova.



Bom pagador: atraso médio de 7 dias em 12 faturas, nada vencido (R$ 101,5 mil a vencer). Fica fora da fila de cobrança e recebe só lembrete preventivo.

Por que os modelos dizem isso. Para cada cliente, a contribuição SHAP de cada variável, na média das suas faturas. As explicações batem com o histórico: no cliente de alto risco, o atraso médio histórico e a proporção de faturas pagas com atraso empurram o risco para cima; no bom pagador, o mesmo atraso médio histórico (7 dias) é o que mais o empurra para baixo, seguido pelo limite de crédito e pelo atraso das últimas faturas.

Próxima ação. O console junta o que os modelos dizem com o que as regras permitem: janela de horário legal (em `America/Sao_Paulo`), limite de tentativas e intervalo medidos na base Bank Marketing, canal preferido do cliente, a faixa da tabela de parcelamento e os limites de alçada.

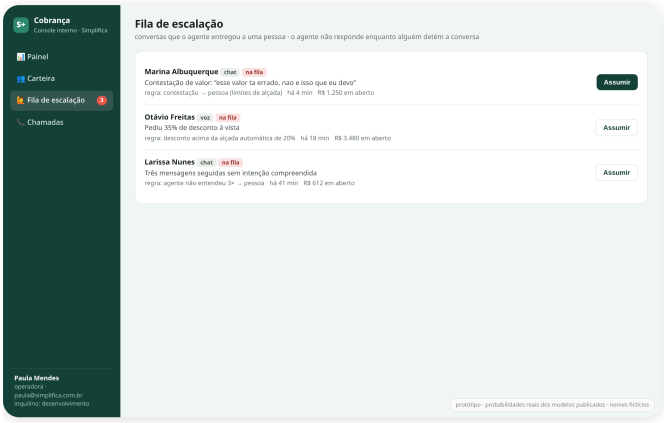


A carteira ordenada pela fila de contato: risco de inadimplência × valor em aberto.

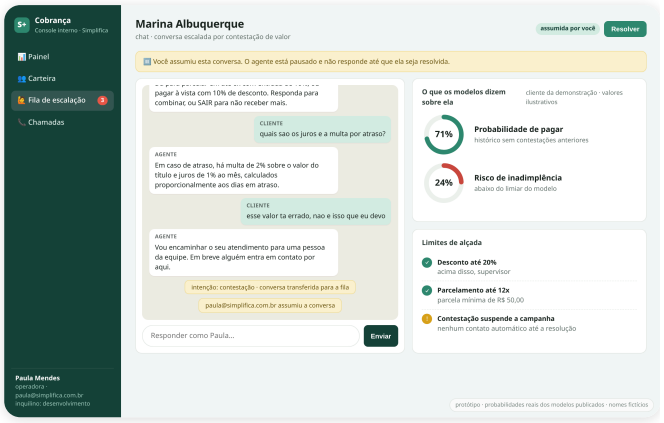


Um cliente no segmento Atenção.

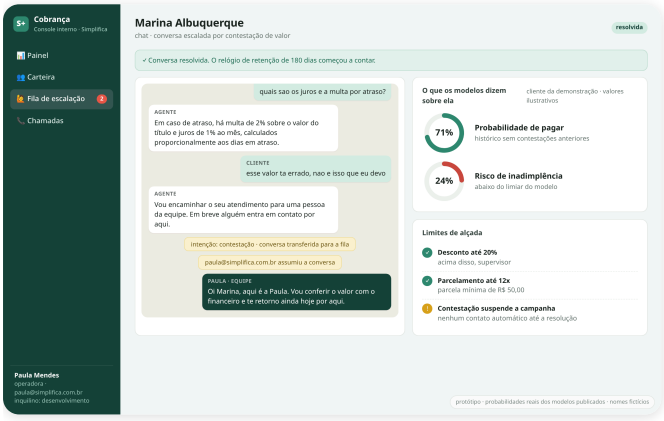
Quando o agente entrega a conversa para uma pessoa



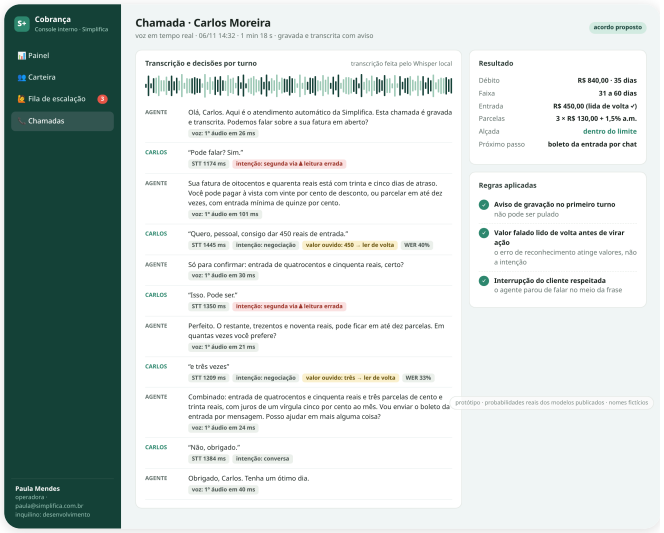
Fila de escalação: cada item diz qual regra mandou a conversa para uma pessoa.



A operadora assume a conversa da Marina, a cliente da demonstração de chat, e o agente fica pausado.



Resolvida: é só a resolução que encerra uma conversa escalada, e é ela que inicia o prazo de retenção de 180 dias.



O registro da chamada de voz: transcrição, decisões de cada turno e o acordo proposto.

A fila e o "assumir/resolver" já existem no código (PR #29, comandos `make queue`, `claim`, `resolve`); o que esta tela acrescenta é a interface.

Notas sobre esta prévia

- **As probabilidades e as explicações são reais**: saem dos modelos publicados (v1), aplicados aos 1.167 clientes da base sintética de demonstração, pelo mesmo caminho do comando `collection score`. O script está em `scripts/export_portfolio.py`.
- **Os nomes são fictícios** e gerados a partir do identificador pseudonimizado. Marina e Carlos são clientes de demonstração; os medidores da Marina são ilustrativos.
- **Contadores do dia** no painel (148 contatos, 12 suprimidos, 3 escalados) são ilustrativos.
- **O texto do agente na chamada é roteirizado** a partir da tabela de parcelamento e dos limites de alçada; a etapa de geração aparece no tempo de turno como 600 ms simulados.
- **As duas vozes são do Piper** (`faber` para o agente, `jeff` para o cliente), rodando localmente: nenhum áudio saiu da máquina. É também a candidata natural para a decisão de TTS da entrega 15.