Prévia do estado atual

Sistema Multiagente Inteligente de Cobrança com LLM, RAG e Machine Learning

Gabriel Forster Rocha · 06/11/2026 — pré-apresentação

Em uma página

O sistema conduz a cobrança de recebíveis com três agentes coordenados por um orquestrador central: um **agente responsivo** que atende o cliente com respostas ancoradas na base de conhecimento (RAG), um **agente proativo** que decide quem contatar, quando e por qual canal dentro das restrições legais, e um **agente preditivo** que ordena a fila por probabilidade de pagamento e de inadimplência futura.

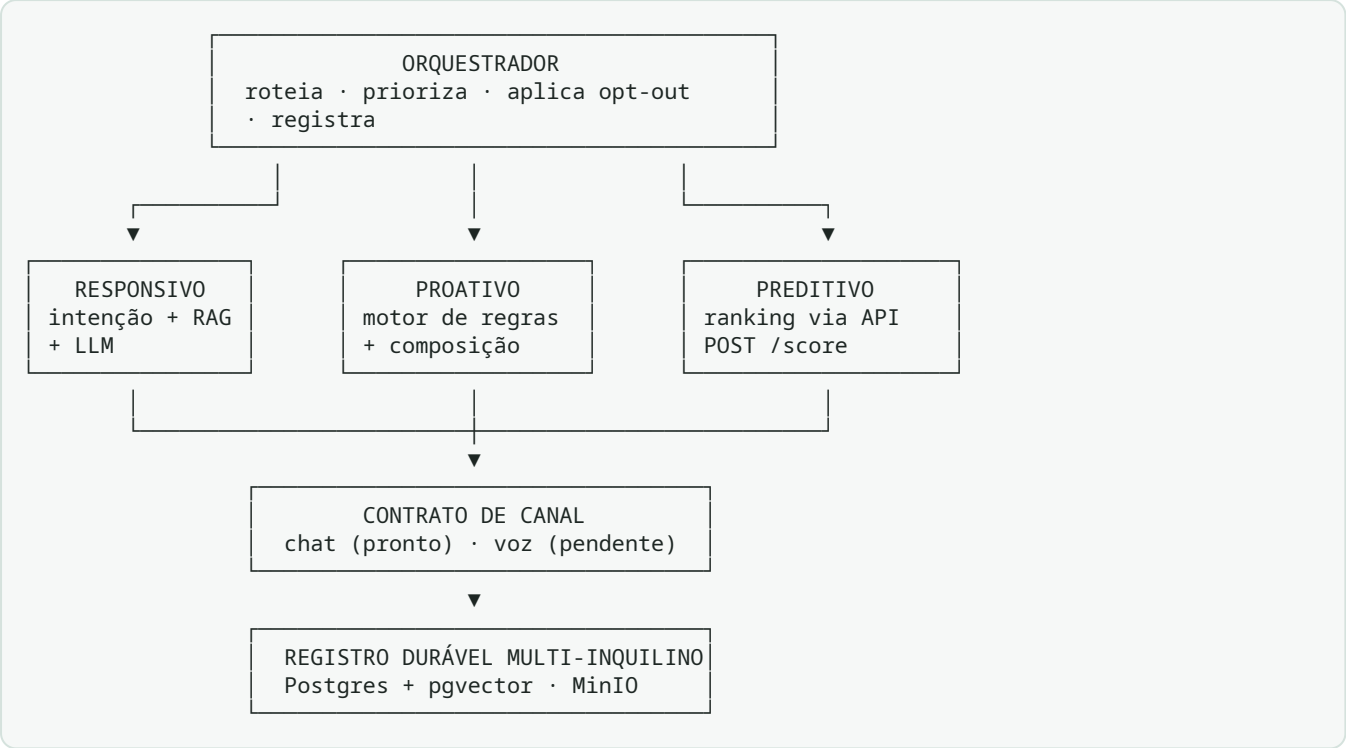
Entregas do cronograma concluídas	14 de 19 (até 29/10)
Pull requests integrados	28
Testes automatizados	689
Código	~14,6 mil linhas de produção · ~8,5 mil de teste
Pendente	voz em tempo real (entrega 15) e a fase de avaliação e redação (16–19)

O que esta prévia mostra: o widget de chat funcionando de ponta a ponta (contato proativo, dúvidas respondidas, contestação escalada para uma pessoa, *opt-out*), os modelos preditivos com suas métricas, e as avaliações já medidas de cada módulo.

Arquivos que acompanham este PDF:

- `video/00-demo-completo.mp4`: demonstração de 49 s com as três cenas
- `video/01-conversa.mp4`, `02-opt-out.mp4`, `03-celular.mp4`: as cenas separadas
- `img/`: todas as capturas e gráficos em alta resolução
- `terminal/`: a saída bruta de cada comando de avaliação executado hoje

Arquitetura

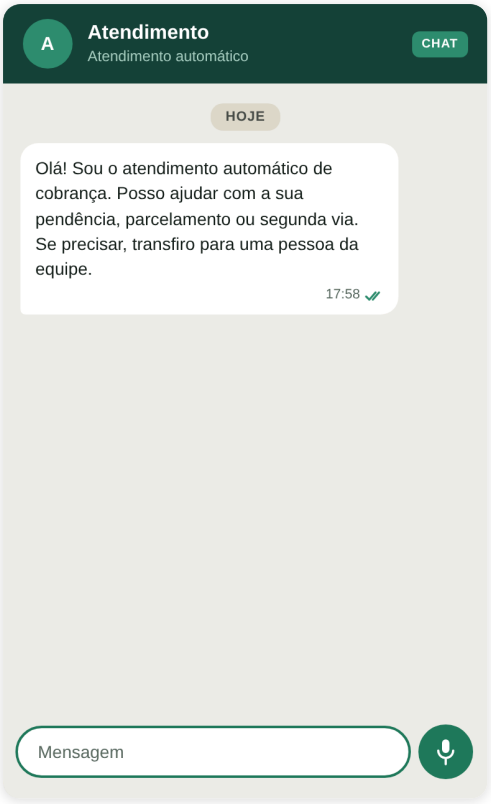


Decisões que sustentam a defesa:

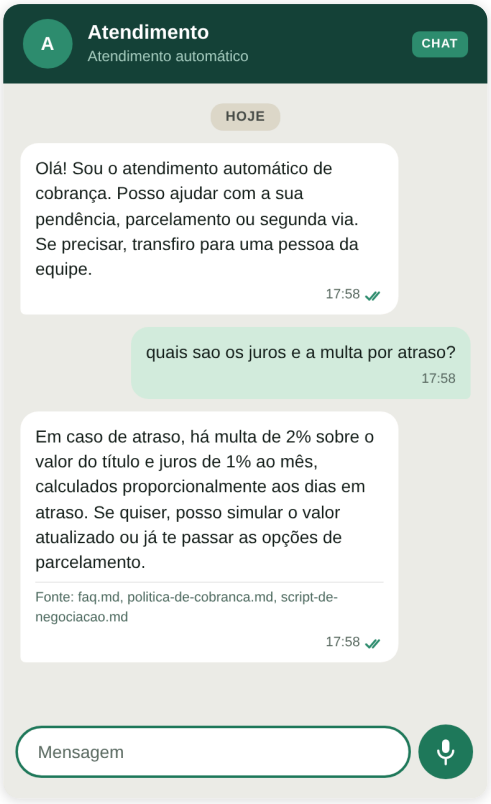
- **O *opt-out* é aplicado pelo orquestrador antes de qualquer agente executar.** Nenhum agente precisa lembrar de respeitá-lo.
- **Nenhum agente importa um canal.** Um teste analisa o código com um parser e falha se isso acontecer, e esse teste tem o próprio teste. É isso que permite trocar WhatsApp por chat, ou telefone por WebRTC, sem tocar nos agentes.
- **Horários de contato são avaliados em `America/Sao_Paulo`, nunca em UTC**: 08:00 UTC são 05:00 no Brasil, um horário proibido.
- **Dados pessoais pseudonimizados** com HMAC-SHA256 e uma chave derivada por inquilino. Transcrições têm retenção de 180 dias (LGPD, art. 15–16).

Demonstração: o canal de chat

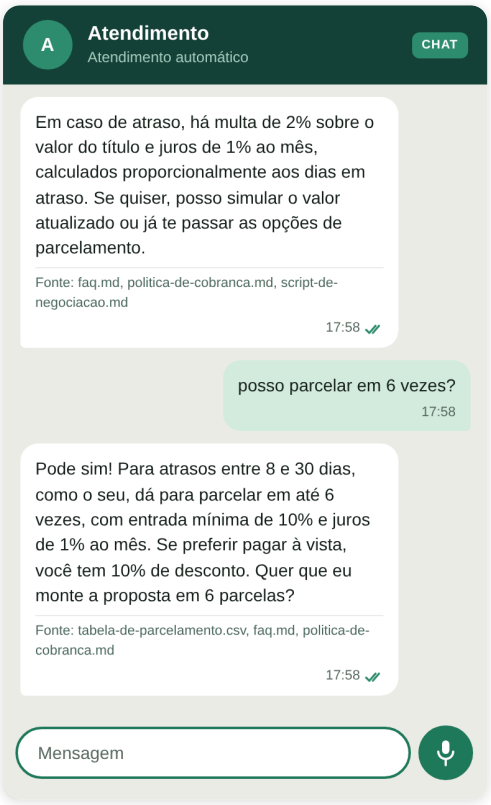
O widget é embutido em qualquer site com uma tag `<script>`, fica isolado em *shadow DOM* e fala com a API do sistema. As cenas abaixo são do servidor real, rodando localmente com o inquilino de demonstração.



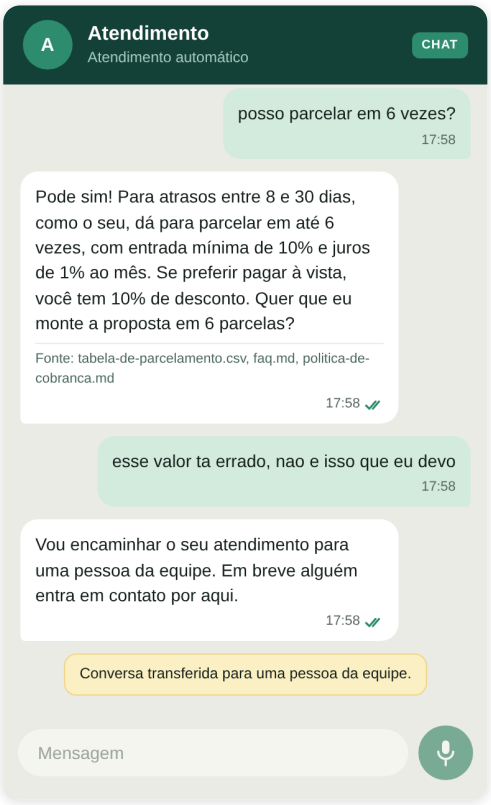
A mensagem que o agente proativo deixou para a cliente, esperando na caixa de entrada quando ela abre o chat. Valor, atraso, condições e a instrução de opt-out vêm do motor de regras e da checagem de conformidade.



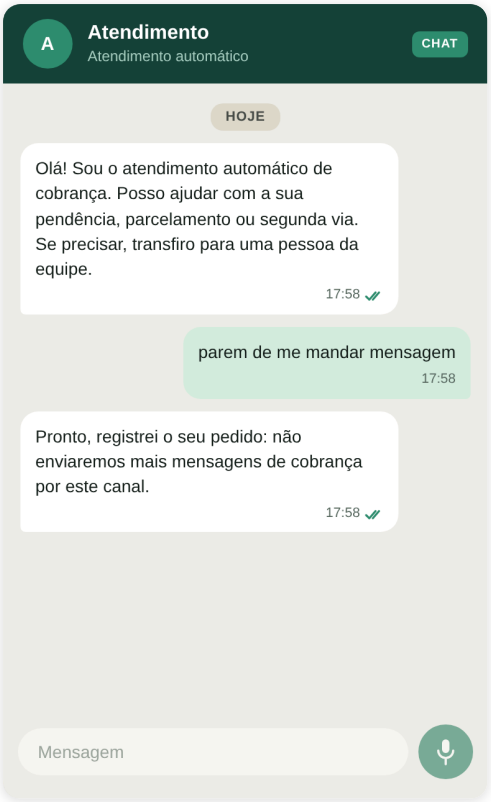
Dúvida sobre juros e multa, respondida a partir do FAQ, com as fontes recuperadas.



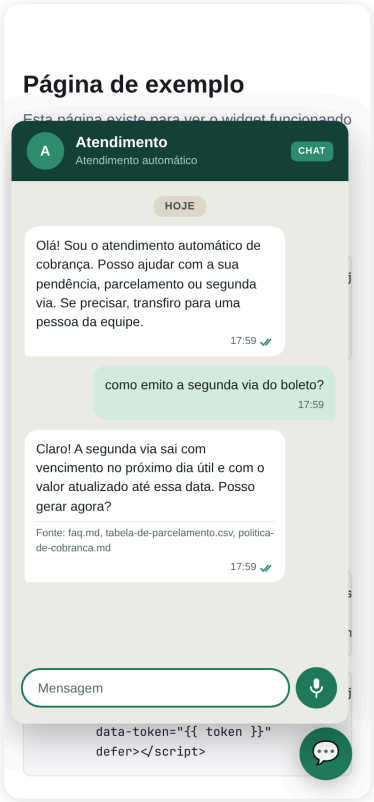
Pedido de parcelamento: a resposta usa a faixa de atraso da cliente (8–30 dias) na tabela de parcelamento.



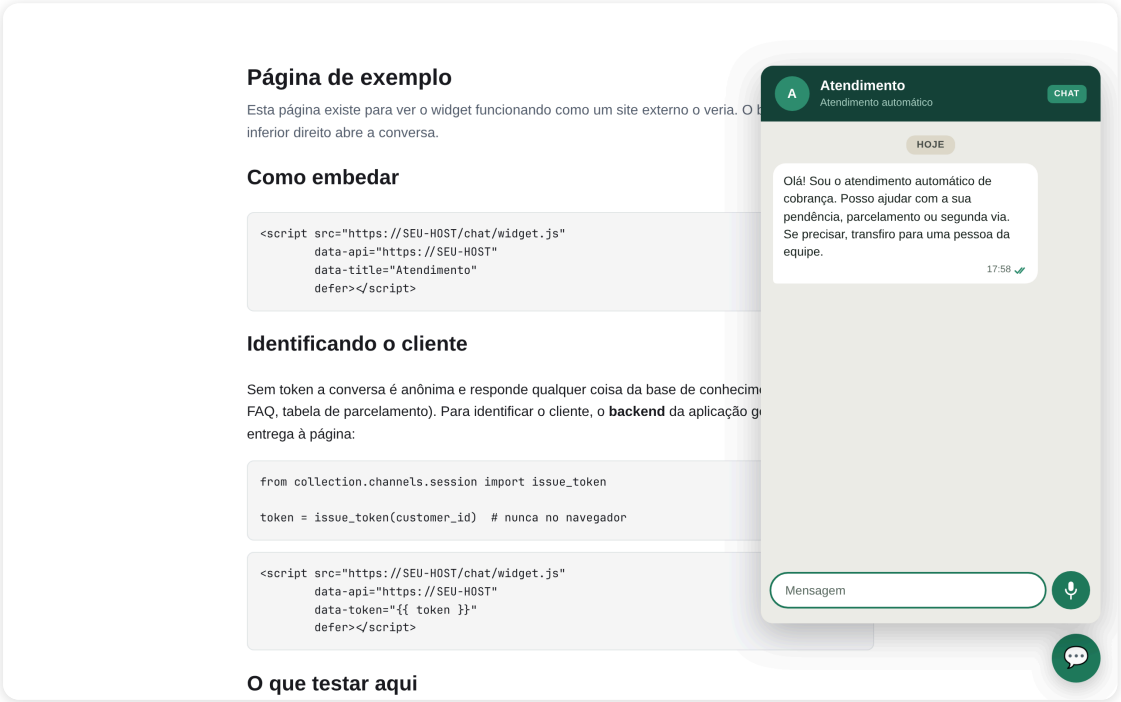
Contestação de valor: o agente não discute, transfere para uma pessoa da equipe e a conversa entra na fila de escalação.



Opt-out: o pedido é registrado e a supressão vale no agendamento e de novo no momento da entrega.



O mesmo widget num celular.



A página de exemplo com o widget aberto. O botão rosa da página hospedeira mostra que o estilo dela não vaza para o widget.

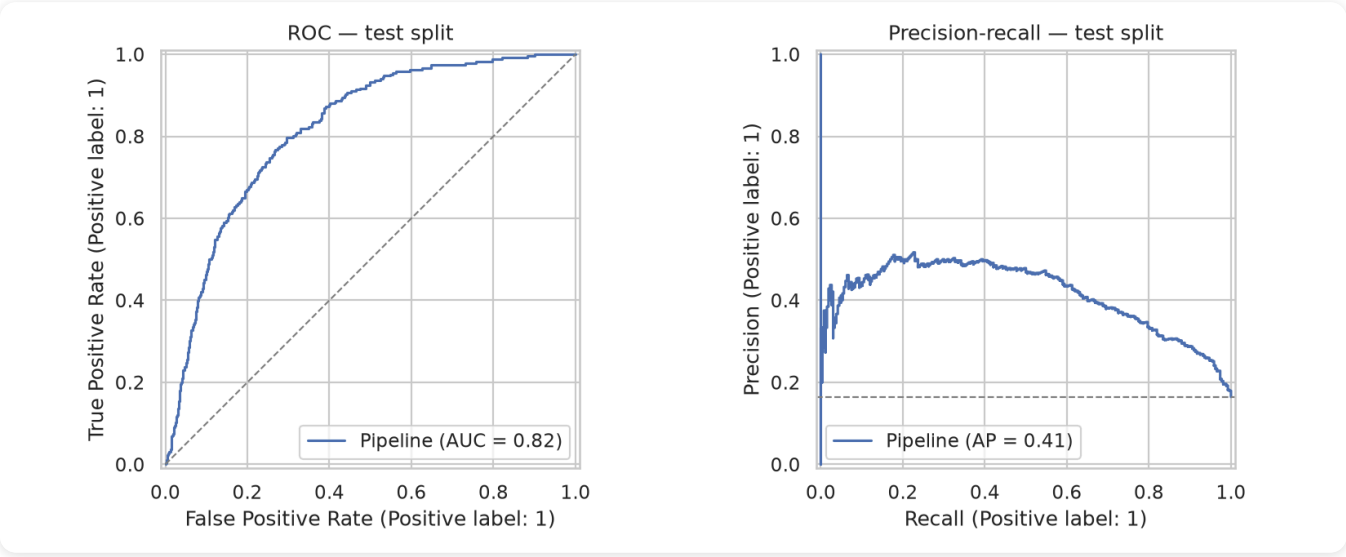
Módulo preditivo

Duas tarefas, ambas com divisão cronológica 70/15/15 (sem vazamento temporal) e validação cruzada `TimeSeriesSplit` com k = 5. O campeão é escolhido por **precisão média (AP)**, nunca por acurácia: com 17% de positivos, prever sempre a classe majoritária já dá 83% de acurácia e não diz nada.

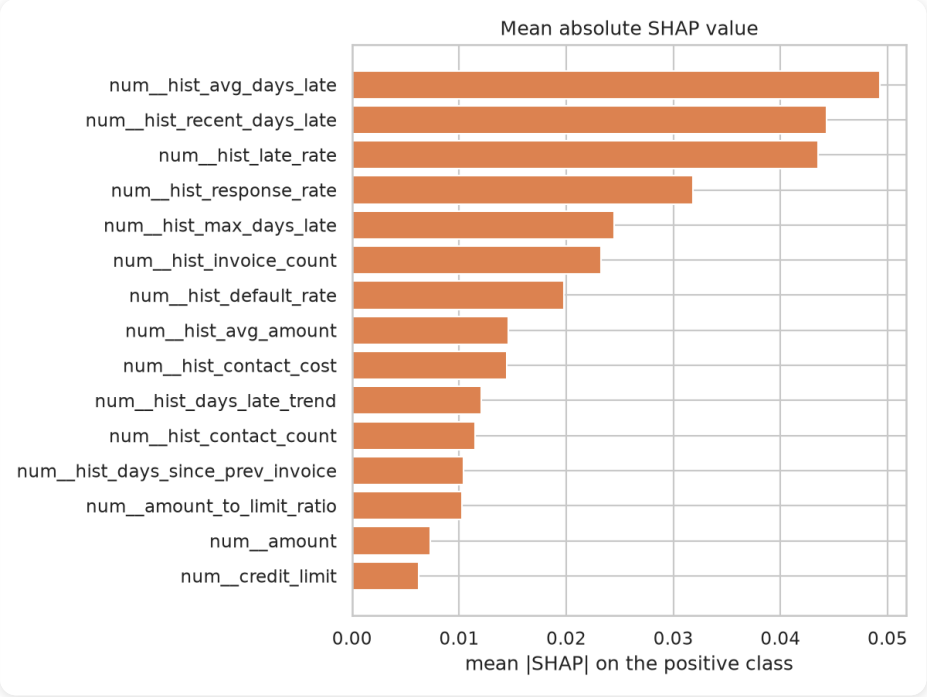
Tarefa	Campeão	AP (teste)	AP de referência[1]	ROC AUC	F1
Propensão ao pagamento	XGBoost + `scale_pos_weight`	**0,851**	0,688	0,735	0,816
Inadimplência futura	XGBoost + `scale_pos_weight`	**0,400**	0,165	0,812	0,491

[1] AP de um classificador sem informação, igual à taxa de positivos no teste.

Seis candidatos por tarefa (regressão logística como baseline, Random Forest e XGBoost, cada um com *class weights* ou SMOTE). Na inadimplência futura o campeão **multiplica por 2,4 a precisão média do acaso**. Executado hoje sobre 11.177 e 10.780 registros sintéticos; 1.169 clientes pontuados pela API.



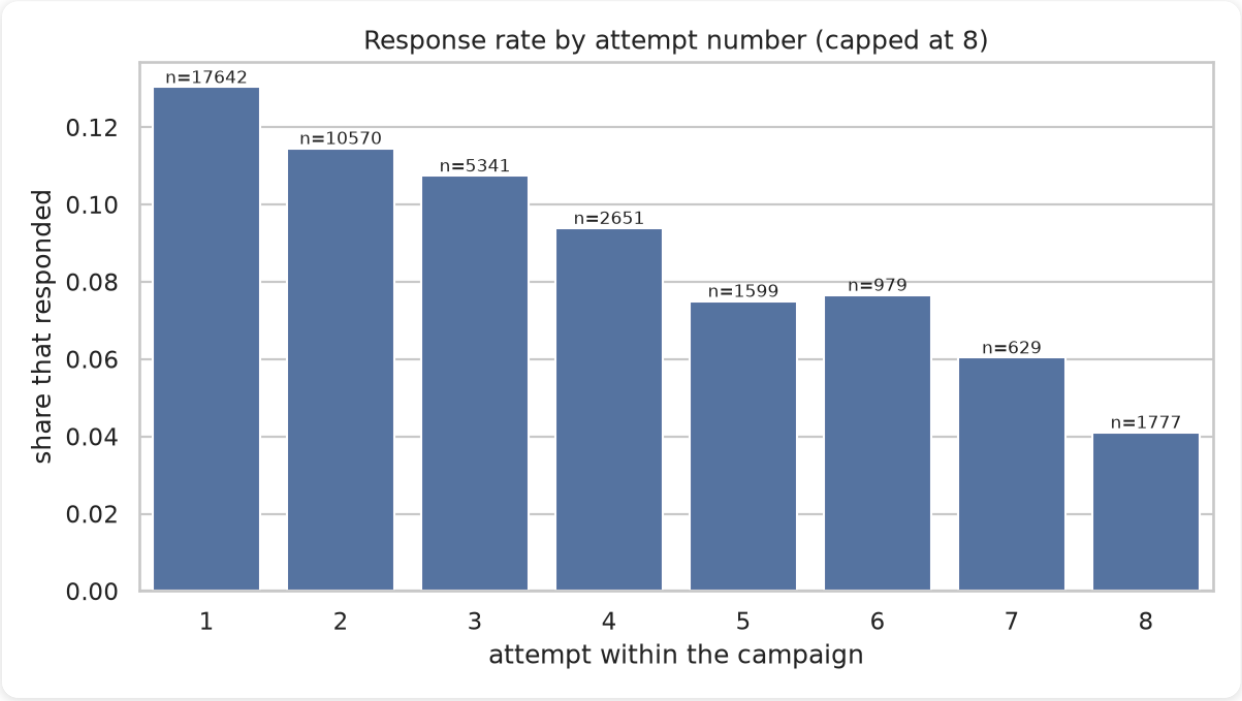
Curvas ROC e precisão–revocação da tarefa de inadimplência futura (relatório versionado).



Importância SHAP das variáveis na tarefa de inadimplência futura.

Regras de contato ancoradas em dado real

A primeira evidência empírica do projeto veio da base pública *Bank Marketing* (UCI): a taxa de resposta **cai de 13,0% para 5,5% ao longo de seis tentativas de contato**, uma queda de 58%. É daí que vêm `max_attempts = 4` e `cooldown = 48 h` no motor de regras: são números medidos, não chutados.



Taxa de resposta por tentativa de contato (Bank Marketing).

O orquestrador, numa rodada de demonstração (`collection demo`): 5 eventos processados, 2 contatos agendados com canal e estágio de atraso, **1 contato suprimido por opt-out antes de chegar a qualquer agente**.

Avaliações já medidas

Cada módulo entra no artigo com um conjunto rotulado e uma comparação entre braços.

Recuperação (RAG), sobre 16 perguntas rotuladas:

k	precisão@k	revocação@k	MRR
1	0,625	0,583	0,625
3	0,375	0,906	0,771
5	0,250	**1,000**	0,783

As perguntas que não ficam em 1º lugar são todas semânticas, não lexicais. Essa é a hipótese para a comparação com *embeddings* neurais.

Respostas (braço de controle, sem LLM), sobre 16 perguntas: 87,5% ancoradas, **100% fiéis** às fontes, 85,7% de citações corretas, mediana de 2,4 ms.

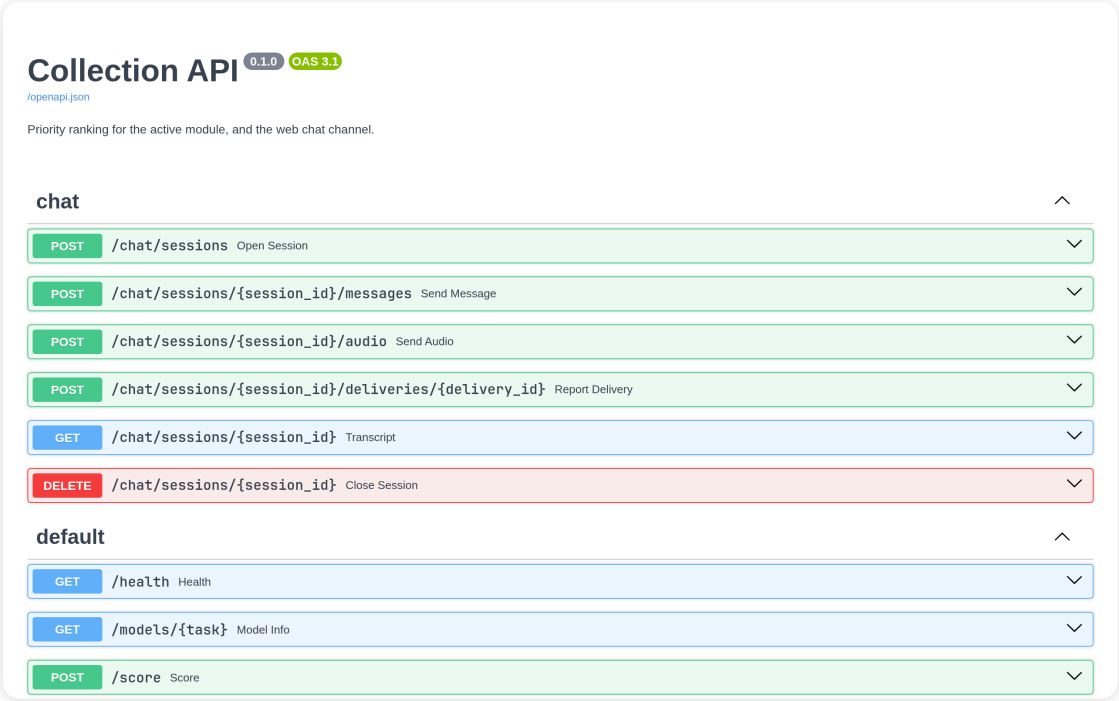
Mensagens ativas, sobre 20 *briefs*: **100% em conformidade** (as cinco checagens legais), **0 valores inventados**, 0 mensagens acima do limite do SMS.

Voz: quanto custa o erro de reconhecimento, sobre 18 áudios rotulados:

WER	intenção preservada	valores intactos	pedem confirmação
0,000	1,000	1,000	0,444
0,046	0,967	0,958	0,444
0,099	0,856	0,867	0,433
0,151	0,833	0,750	0,433

O erro não degrada o sistema de forma uniforme: a intenção sobrevive, mas um valor falado uma vez não. Com WER de ~10%, uma transcrição que se lê perfeitamente, um valor em cada sete já está errado. Por isso **todo valor ouvido em áudio é lido de volta antes de virar ação**.

A API



Os endpoints: o canal de chat (sessões, mensagens, áudio, recibos de entrega) e a pontuação preditiva.

O que falta

#	Data	Entrega	Estado
15	05/11	Chamada de voz em tempo real (WebRTC/LiveKit) + tabela de tempo de turno	**não iniciada**: falta escolher o TTS
16	12/11	Suíte de testes + experimento controlado contra os dois baselines	testes prontos (689); experimento a desenhar
17	19/11	Resultados consolidados e análise estatística	metade medida (acima); braços com LLM ainda não executados
18	26/11	Artigo completo revisado	o artigo ainda está na versão de proposta
19	03/12	Versão final, *slides*, defesa	—



Protótipo de tela do canal de voz em tempo real (entrega 15).

Mudanças de escopo já registradas (`cronograma.md`, §2): a WhatsApp Business API foi trocada pelo canal de chat simulado, e a telefonia comutada pela chamada WebRTC. O critério: uma integração só entra se acrescentar uma decisão nova a algum agente. Ambas acrescentariam apenas transporte, conta comercial e contrato de faturamento.

Notas sobre esta prévia

- **Os dados são sintéticos ou públicos.** A extração do ERP não aconteceu; a comparação operacional antes/depois virou limitação documentada (`docs/data-acquisition-plan.md`).
- **O texto das respostas no chat foi gerado por um modelo simulado.** Não havia chave de API de LLM configurada nesta máquina, então a etapa de geração foi substituída por respostas roteirizadas, escritas a partir dos mesmos documentos da base. Recuperação, classificação de intenção, escalação, *opt-out* e recibos de entrega são o código real. Sem chave, o sistema real responde citando os trechos recuperados na íntegra.
- As métricas desta prévia vêm de execuções de 06/11/2026; a saída bruta está em `terminal/`.