PRÉ-APRESENTAÇÃO · TCC · ENGENHARIA DE SOFTWARE

Sistema Multiagente Inteligente de Cobrança

com LLM, RAG e Machine Learning — como o projeto está hoje

14 / 19
entregas do cronograma

689
testes automatizados

1.167
clientes pontuados pelos modelos

3
agentes coordenados

Gabriel Forster Rocha · 06/11/2026

VISÃO GERAL

O que o sistema faz

Três agentes, coordenados por um orquestrador central, conduzem a cobrança dentro das regras legais. O cliente conversa por chat (e, em breve, por voz); a equipe acompanha por um console interno.

Os três agentes

- **Responsivo:** atende o cliente com respostas tiradas da base de conhecimento (RAG).
- **Proativo:** decide quem contatar, quando e por qual canal, respeitando horário, limite de tentativas e *opt-out*.
- **Preditivo:** estima quem vai pagar e quem vai ficar inadimplente, e ordena a fila.

Garantias que valem para todos

- O *opt-out* é aplicado **antes** de qualquer agente agir.
- Horário de contato sempre no fuso de São Paulo.
- Contestação de valor vai para uma pessoa, nunca para a campanha.
- Dados pessoais pseudonimizados (LGPD); conversas guardadas por 180 dias.

1

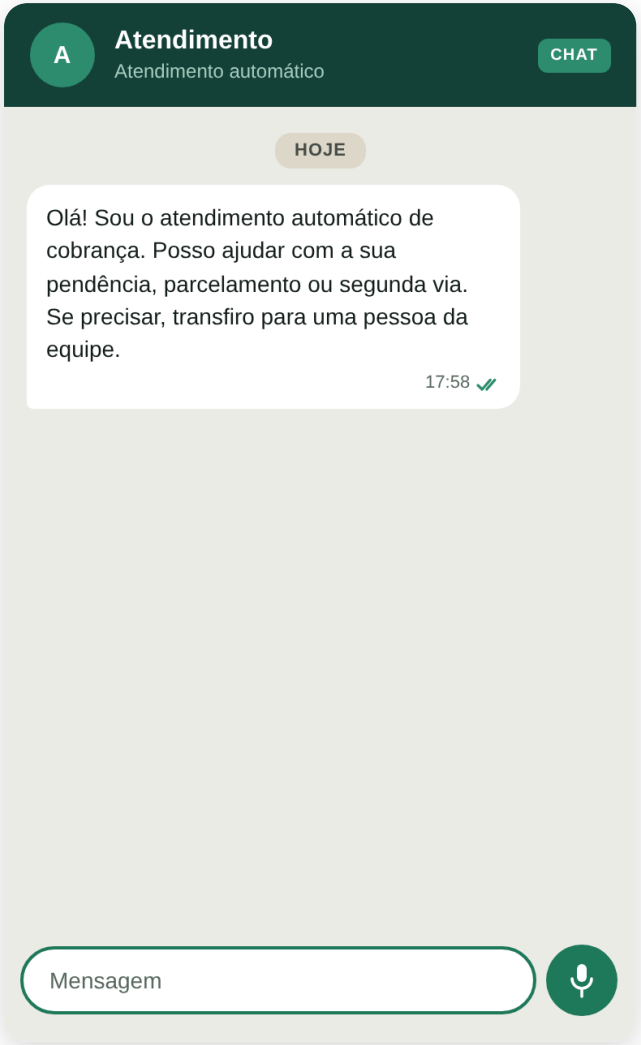
O chat com o cliente

Funcionando de ponta a ponta. Um widget que qualquer site pode embutir.

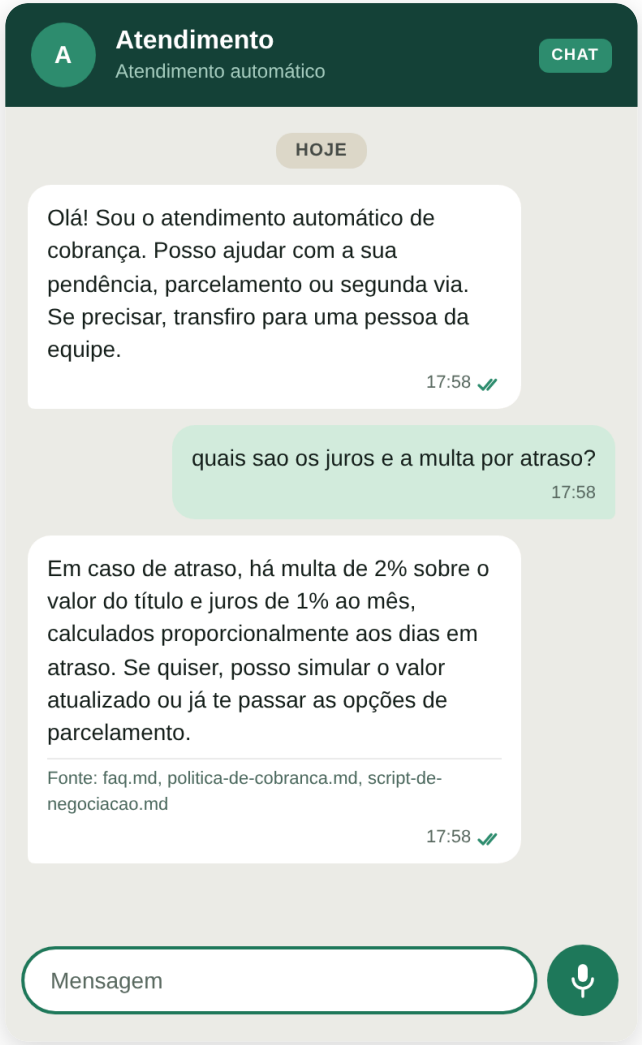
CHAT

O sistema puxa a conversa e responde dúvidas

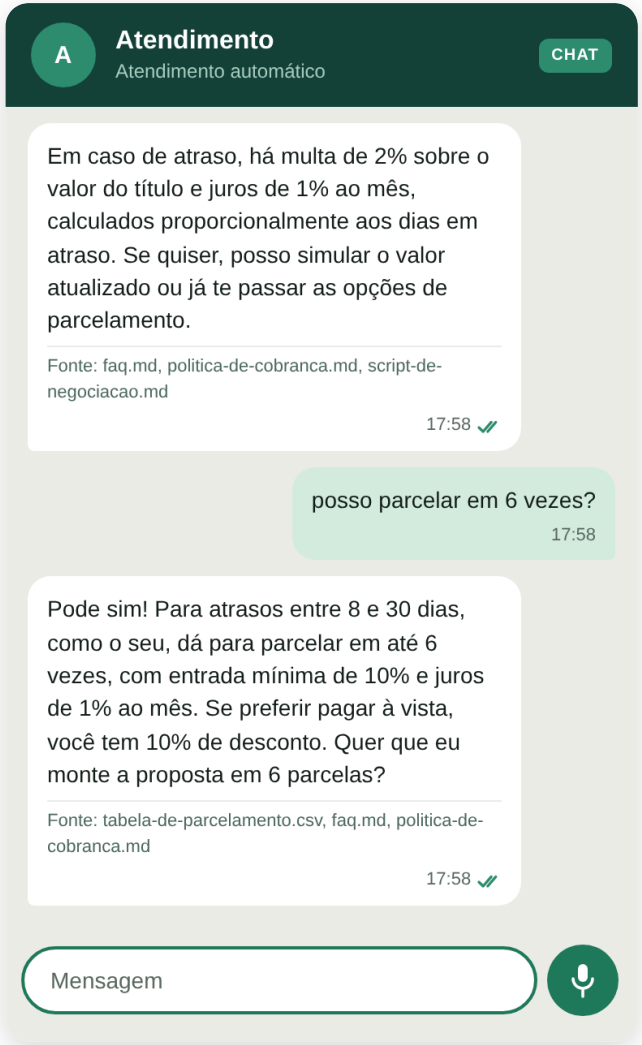
O agente proativo deixa uma mensagem com valor, atraso e condições. Quando o cliente pergunta, a resposta vem da base de conhecimento.



A mensagem proativa esperando a cliente



Juros e multa, respondidos pelo FAQ

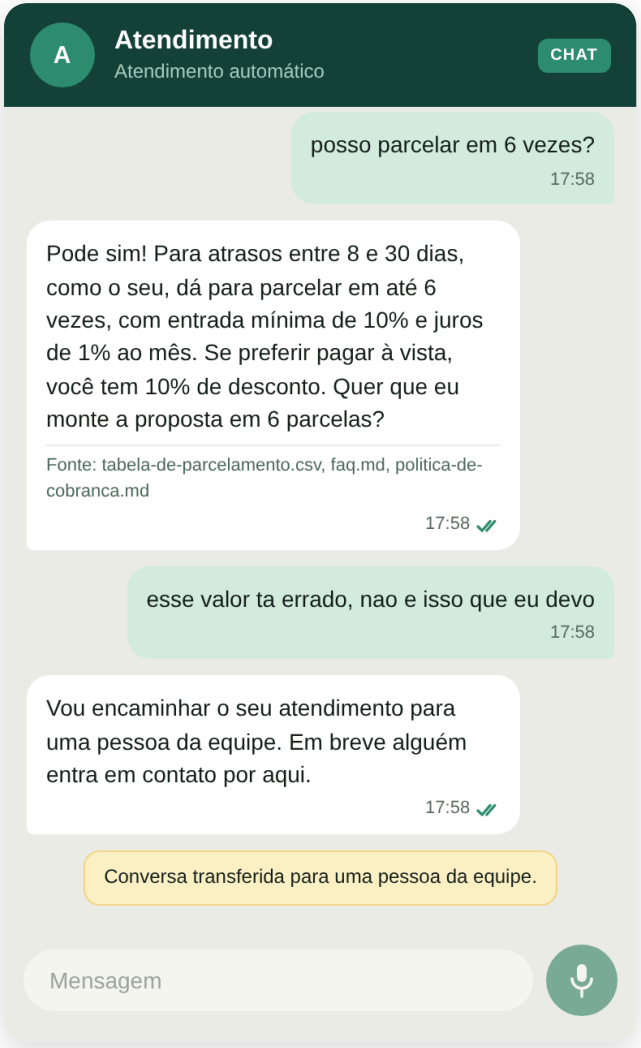


Parcelamento pela faixa de atraso dela

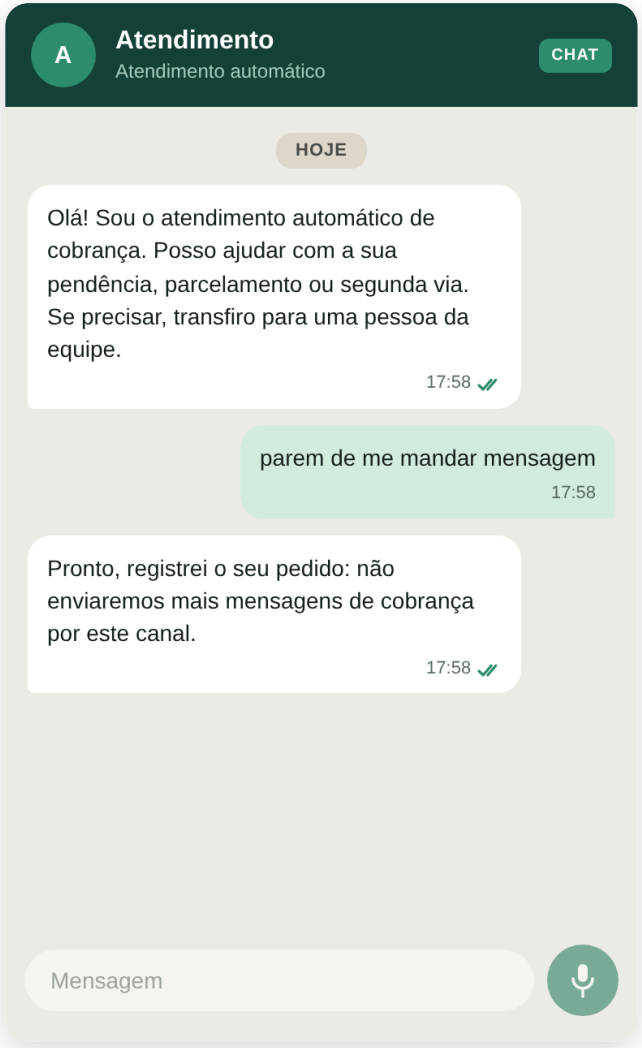
CHAT

Quando parar e quando chamar uma pessoa

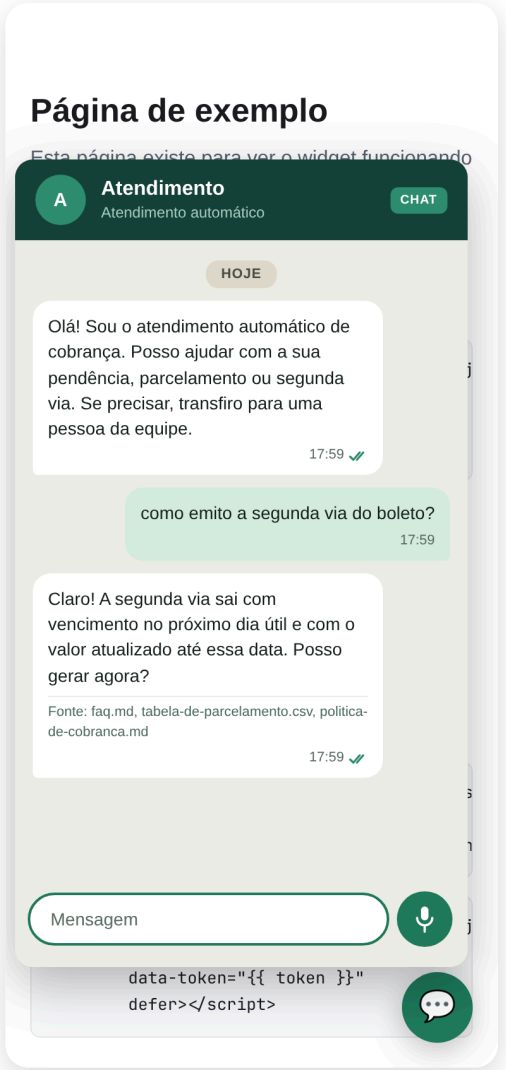
Se o cliente contesta o valor, o agente não discute: transfere para a equipe. Se pede para não receber mais mensagens, o pedido é registrado na hora.



Contestação → transferida para uma pessoa



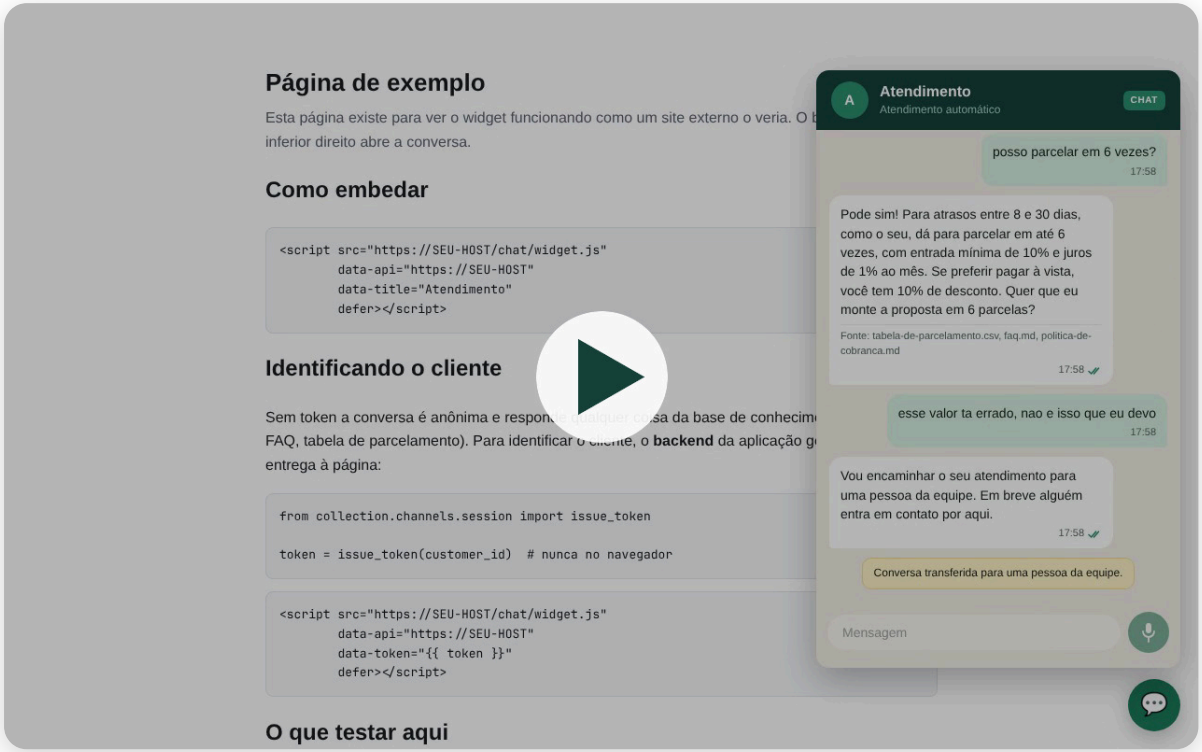
Opt-out registrado



O mesmo widget no celular

VÍDEO · 49 S

Demonstração do chat



Contato proativo, dúvidas respondidas, contestação escalada, *opt-out* e a versão no celular.

`preview/2026-11-06/video/00-demo-completo.mp4`

Abrir no GitHub →

Nesta demonstração o texto das respostas foi gerado por um modelo simulado (sem chave de LLM na máquina). Busca na base, intenção, escalação e *opt-out* são o código real.

2

Os modelos preditivos

Quem vai pagar? Quem vai ficar inadimplente? Dois modelos treinados, avaliados e servidos por uma API.

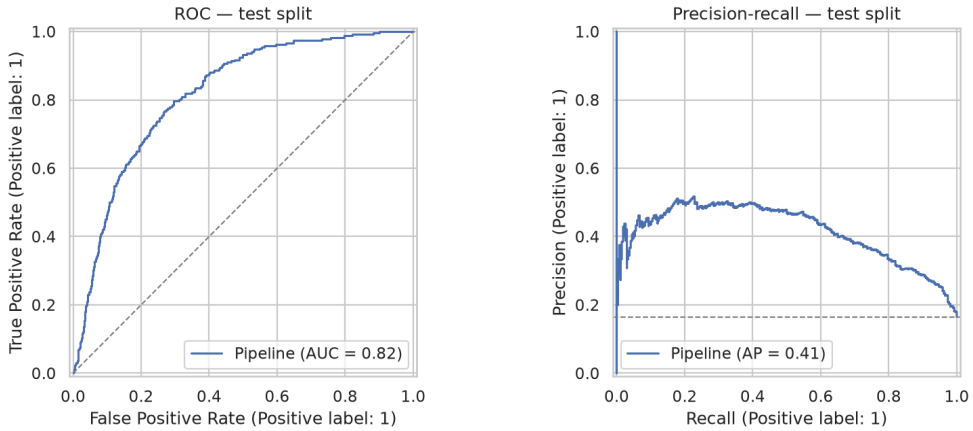
MODELOS

Melhores que o acaso, medidos do jeito certo

O campeão é escolhido pela precisão média, não pela acurácia: com 17% de inadimplentes, “ninguém vai inadimplir” já acerta 83% e não diz nada.

Tarefa	Modelo	Acaso
Propensão a pagar	**0,85**	0,69
Inadimplência futura	**0,40**	0,17

Precisão média no conjunto de teste. XGBoost nas duas tarefas, escolhido entre seis candidatos. Na inadimplência, o modelo multiplica por 2,4 o resultado do acaso.

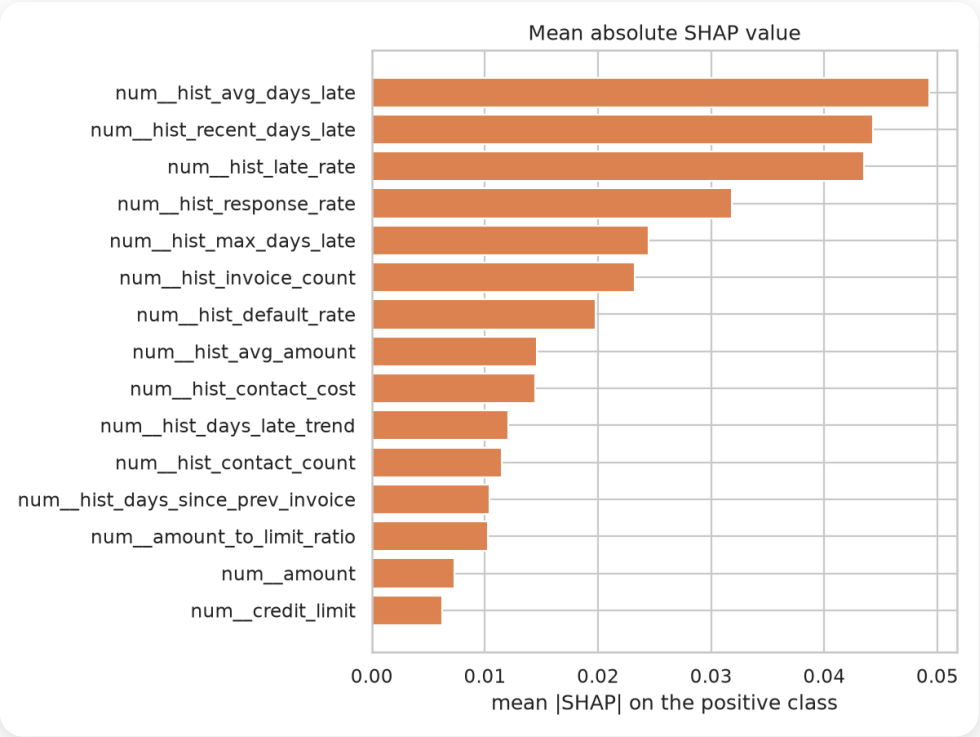


Curvas ROC e precisão–revocação, inadimplência futura

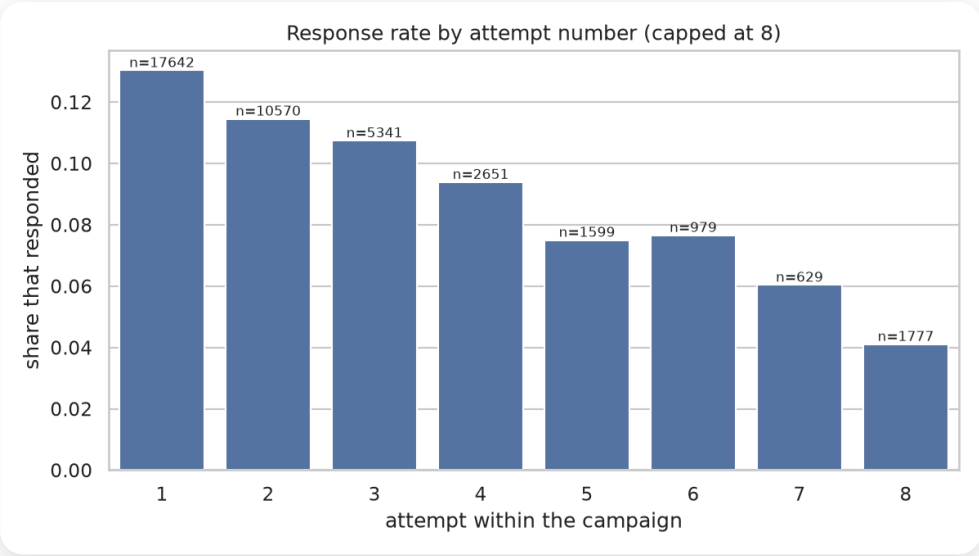
MODELOS E REGRAS

O que pesa na decisão, e quando parar de insistir

O histórico de atraso é o que mais pesa no risco. E a taxa de resposta cai de 13% para 5,5% ao longo de seis tentativas, por isso o sistema para na quarta.



Importância de cada variável (SHAP)



Taxa de resposta por tentativa (base pública Bank Marketing)

3

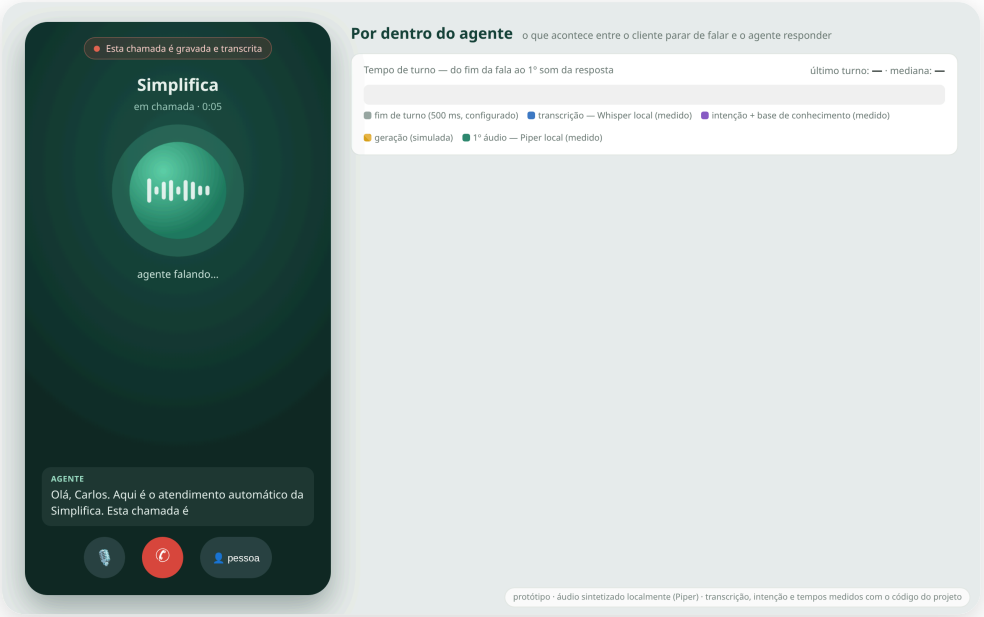
A chamada de voz

Protótipo da próxima entrega. Vozes geradas localmente; transcrição, intenção e tempos medidos com o código do projeto.

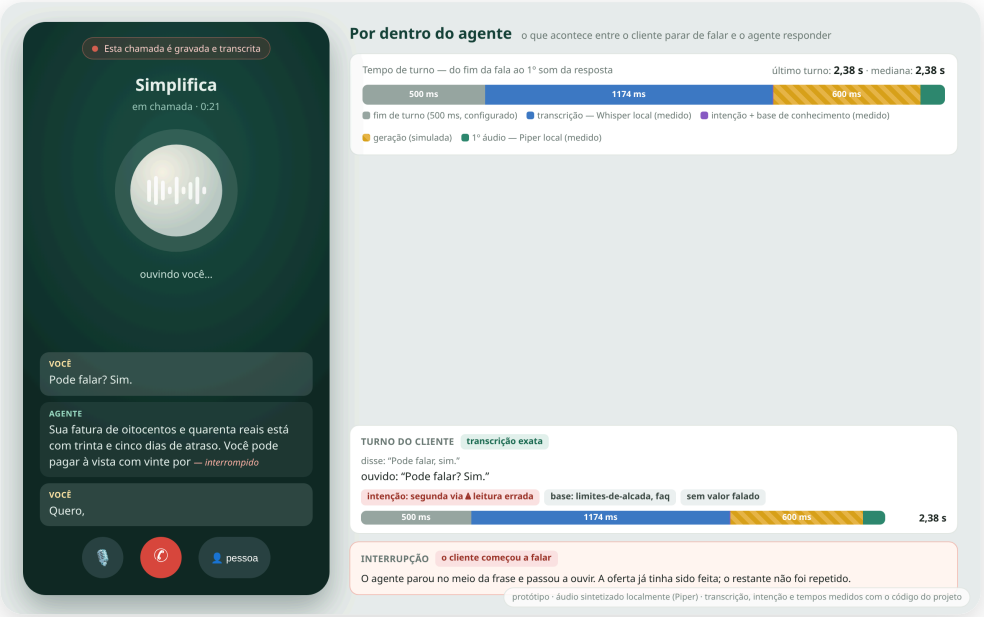
VOZ · PROTÓTIPO

Uma chamada no navegador

O aviso de gravação vem primeiro e não pode ser pulado. Se o cliente interrompe, o agente para de falar.



Abertura com o aviso de gravação

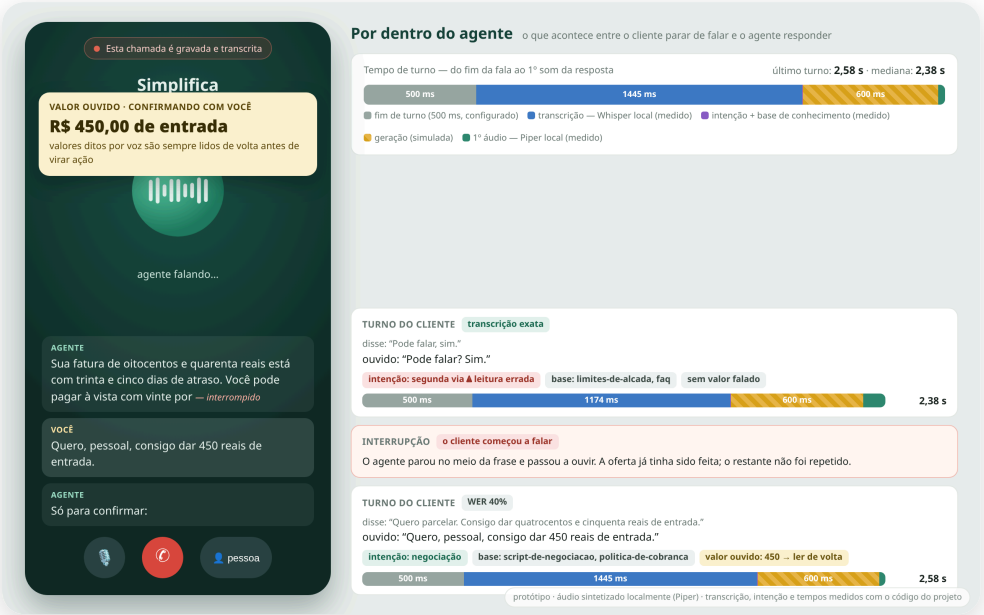


O cliente interrompe; o agente para

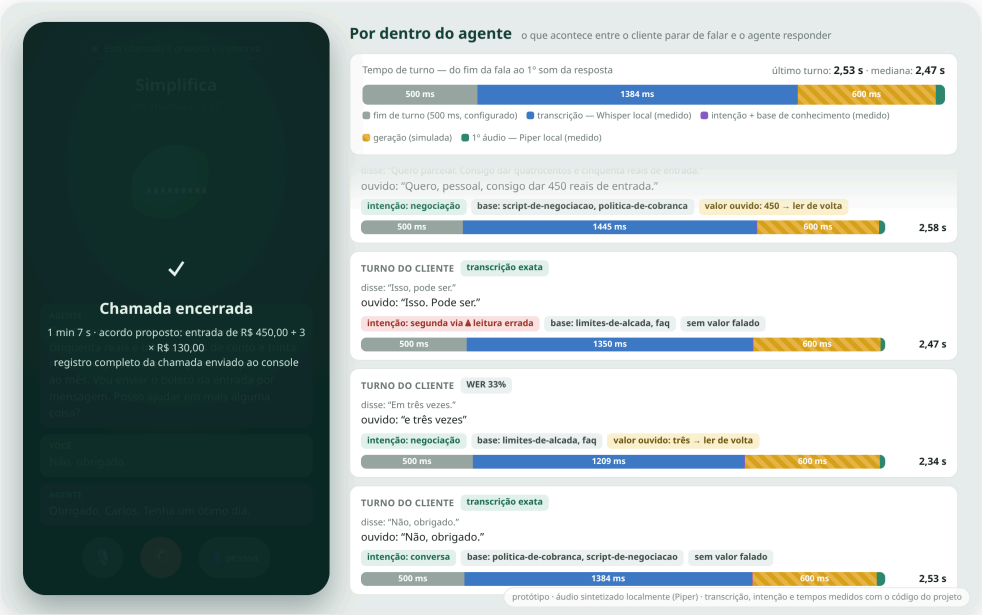
VOZ · PROTÓTIPO

Todo valor falado é confirmado

Um valor ouvido por voz nunca vira ação direto: o agente lê de volta e espera a confirmação. A chamada termina com um acordo dentro dos limites da operação.



"R$ 450,00 de entrada" — lido de volta



Acordo: entrada de R$ 450 + 3 × R$ 130

VOZ · MEDIDO

Quanto tempo o agente leva para responder

Do fim da fala do cliente ao primeiro som da resposta: **cerca de 2,5 s**. Quase metade é a transcrição.

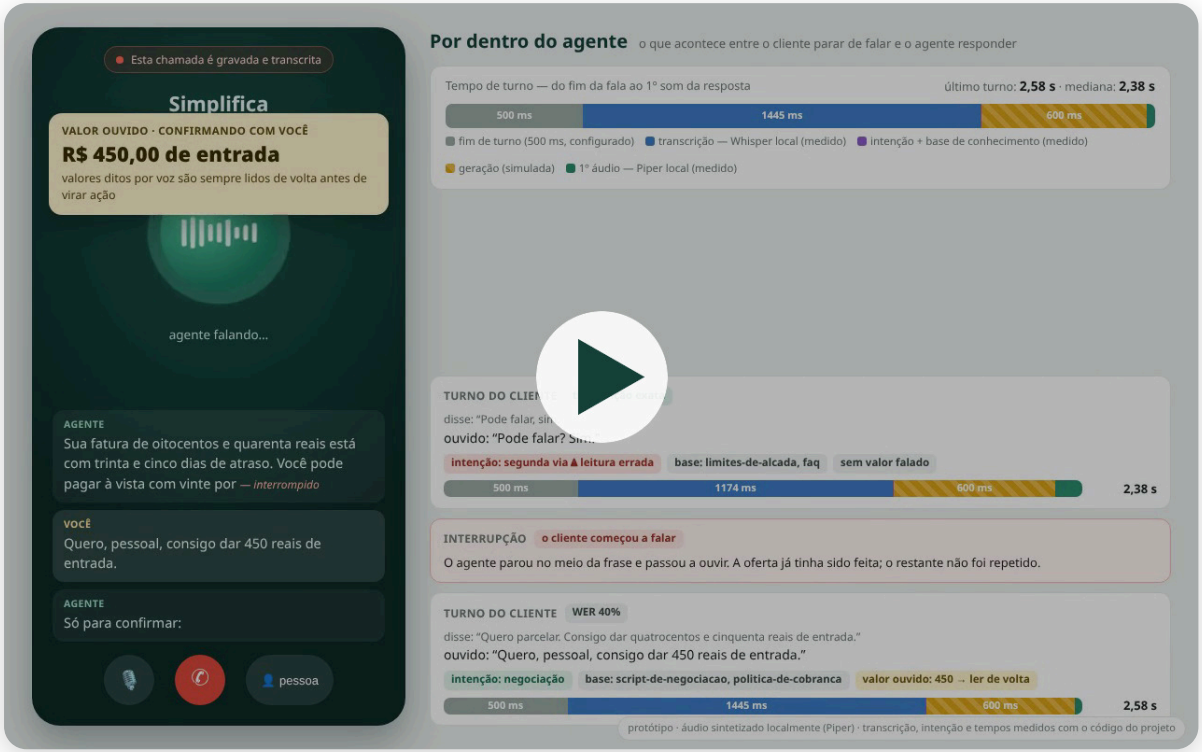
Etapa	Tempo	
Esperar o cliente terminar	500 ms	configurado
Transcrever a fala (Whisper)	**~1.300 ms**	medido
Entender e consultar a base	~3 ms	medido
Escrever a resposta	600 ms	simulado
Começar a falar (Piper)	**21–101 ms**	medido

O que aprendemos

- A voz local é quase instantânea; **o gargalo é a transcrição**.
- Erros de reconhecimento atingem os **valores**, não a intenção. Por isso a leitura de volta.
- Um “sim” isolado foi mal interpretado. A correção já está definida para a entrega de voz.

VÍDEO · 69 S · COM ÁUDIO

A chamada completa



A chamada inteira, com as duas vozes e o painel "por dentro do agente" mostrando o que foi ouvido, entendido e quanto tempo levou.

`preview/2026-11-06-voz-console/video/02-chamada-de-voz.mp4`

Abrir no GitHub →

4

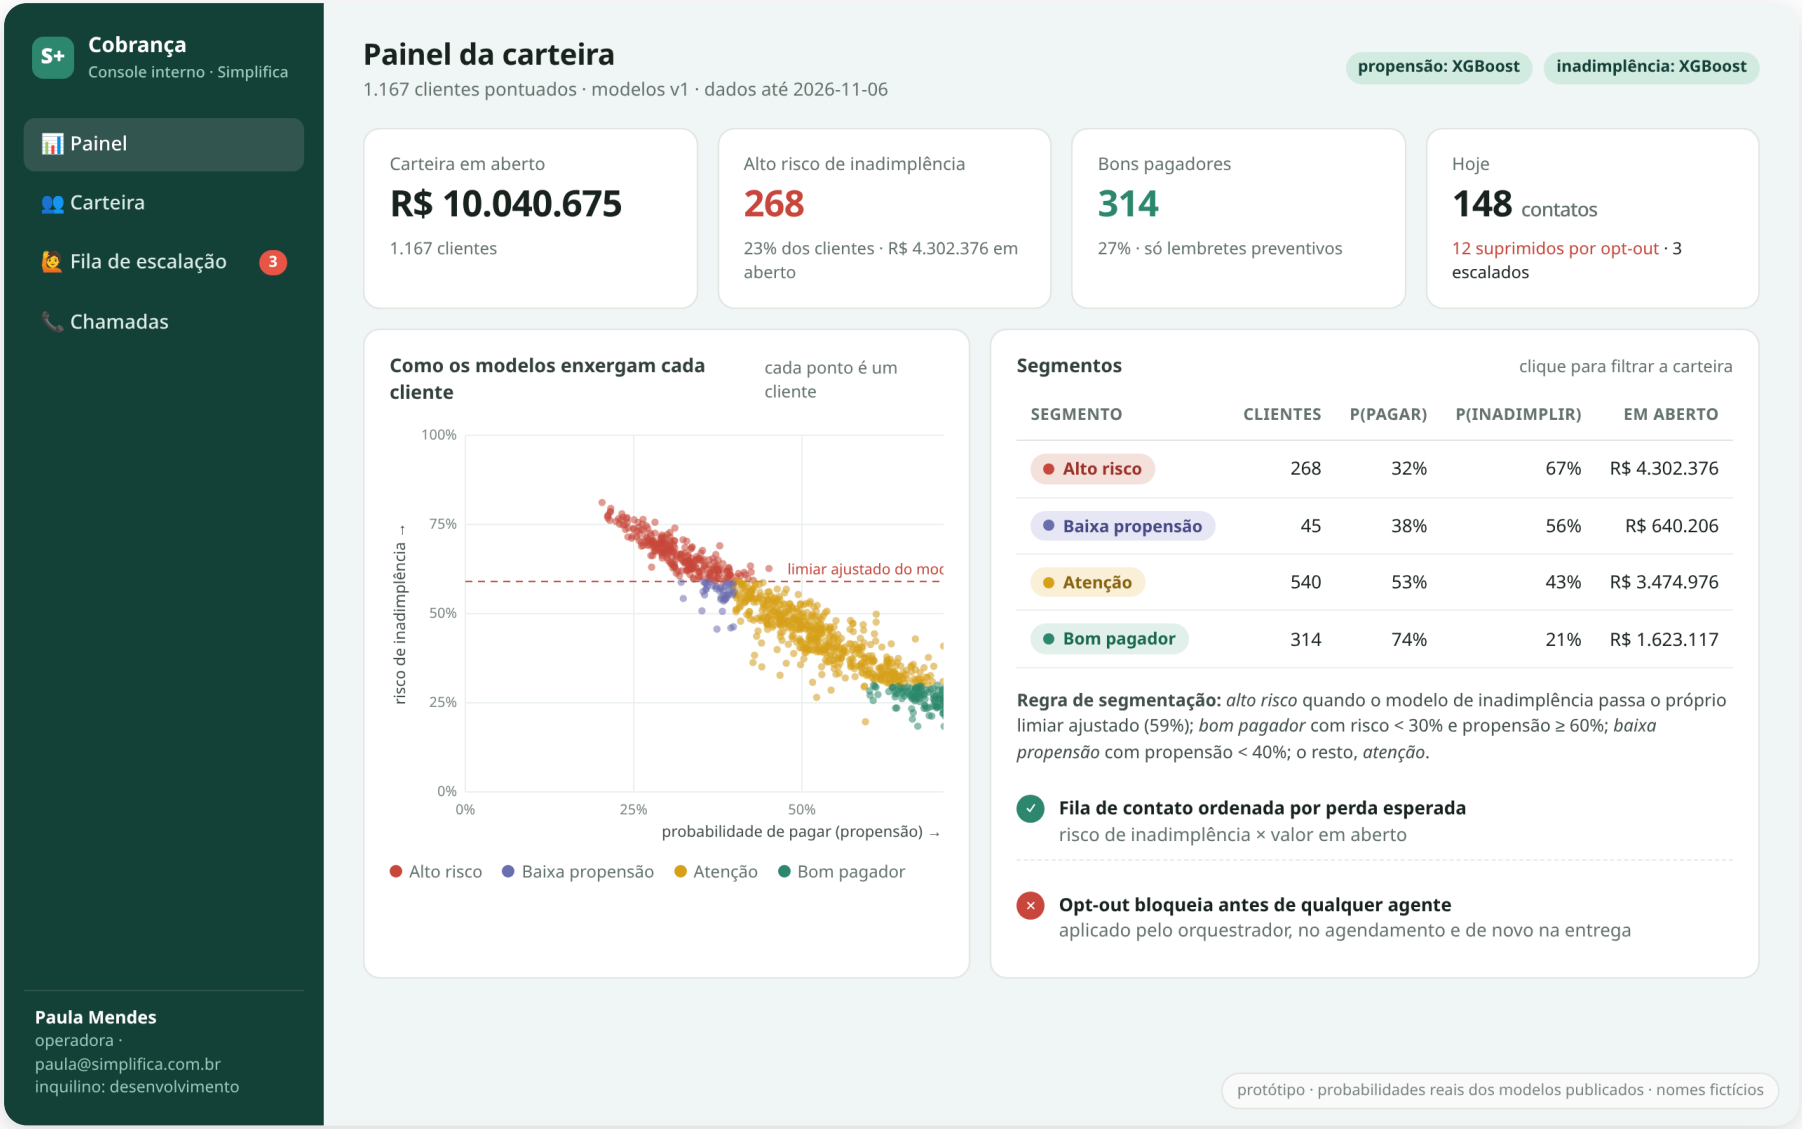
O console interno

Protótipo de tela para a equipe de cobrança, com as probabilidades reais dos modelos para cada cliente.

CONSOLE · PROBABILIDADES REAIS

Como os modelos enxergam a carteira

Cada ponto é um cliente. Os modelos separam a carteira em quatro grupos com comportamentos realmente diferentes.



CONSOLE

Os quatro grupos

Ninguém desenhou esses grupos à mão: eles saem das duas probabilidades. O histórico confirma a diferença.

Grupo	Clientes	Chance de pagar	Risco de inadimplência	Atraso médio no histórico
Alto risco	268	32%	67%	178 dias
Baixa propensão	45	38%	56%	113 dias
Atenção	540	53%	43%	41 dias
Bom pagador	314	74%	21%	7 dias

Os bons pagadores ficam fora da fila de cobrança e recebem só lembretes antes do vencimento. A fila de contato é ordenada por risco de inadimplência × valor em aberto.

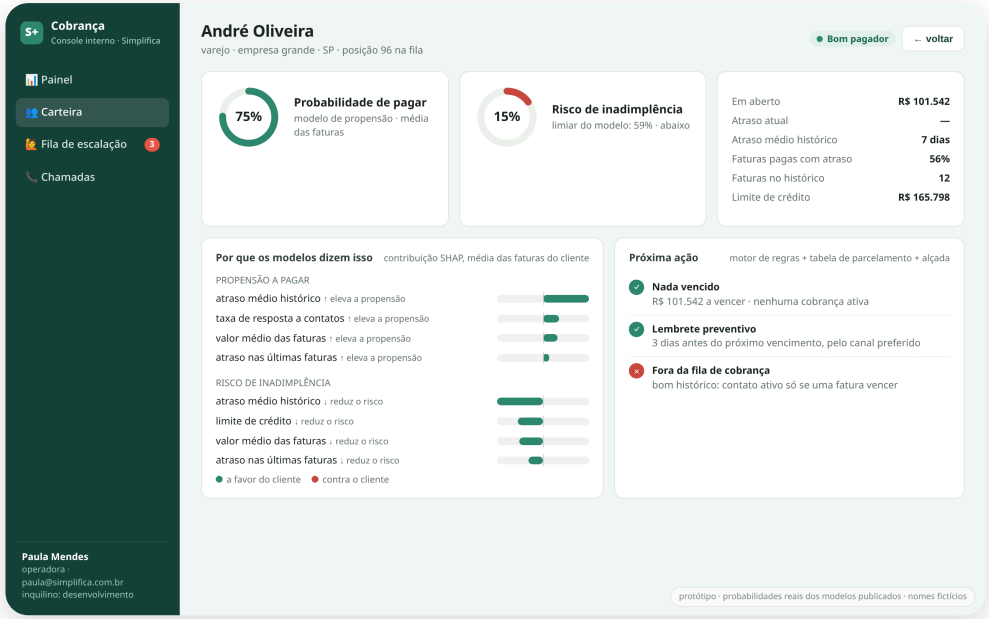
CONSOLE · EXPLICAÇÃO POR CLIENTE

Por que o modelo diz isso sobre este cliente?

Para cada cliente, o console mostra o que pesou a favor e contra, e qual é a próxima ação permitida pelas regras.



Alto risco: 683 dias de atraso. A tabela permitiria 18 parcelas, mas acima de 12 precisa de uma pessoa.

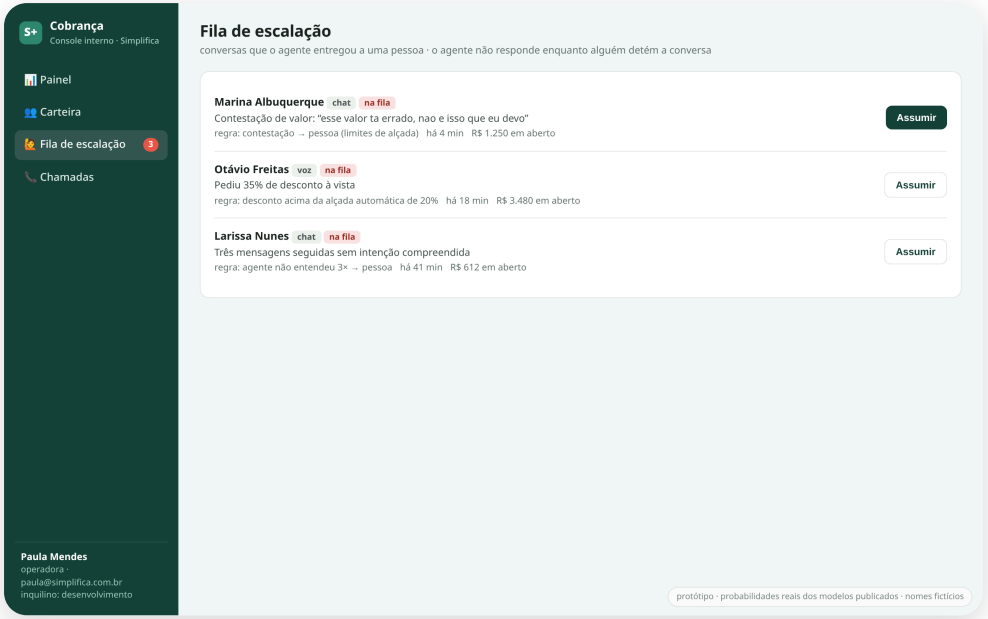


Bom pagador: atraso médio de 7 dias, nada vencido. Só lembrete preventivo.

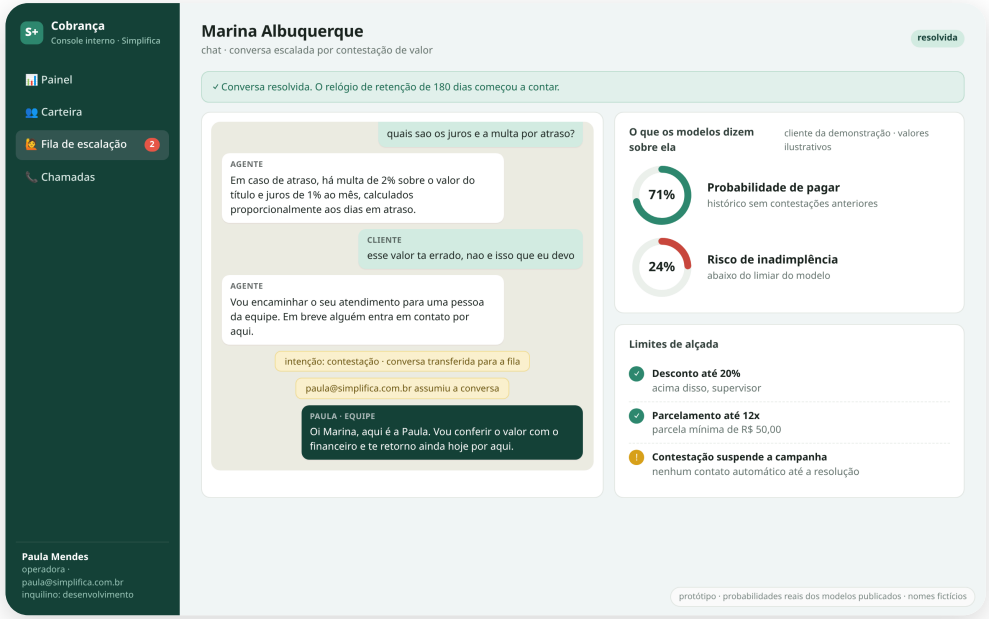
CONSOLE

Quando o agente passa a conversa para uma pessoa

A fila mostra por que cada conversa foi escalada. A operadora assume, o agente pausa, e só ela pode encerrar.



Fila de escalação



Conversa assumida e resolvida

VÍDEO · 40 S

Percurso pelo console



Painel → carteira de alto risco → um cliente → um bom pagador → fila de escalação → a operadora assume e resolve → o registro da chamada de voz.

`preview/2026-11-06-voz-console/video/01-console.mp4`

Abrir no GitHub →

Versão com voz e console juntos, com cartelas:

`preview/2026-11-06-voz-console/video/00-demo-voz-e-console.mp4`

PRÓXIMOS PASSOS

O que falta até a defesa

Data	Entrega	Estado
05/11	Chamada de voz em tempo real	**protótipo pronto**
12/11	Testes + experimento controlado	**testes prontos**
19/11	Resultados consolidados	**metade medida**
26/11	Artigo completo revisado	**a escrever**
03/12	Versão final e defesa	—

Sobre esta prévia

- Os dados são **sintéticos ou públicos**; nenhum dado real de cliente.
- As **probabilidades e explicações** do console são dos modelos treinados.
- Voz e console são **protótipos de tela**; nomes fictícios.
- O texto gerado pelo agente foi **simulado** (sem chave de LLM na máquina).