

Sistema Multiagente Inteligente de Cobrança com LLM, RAG e Machine Learning

Intelligent Multi-Agent Collection System with LLM, RAG and Machine Learning

Gabriel Forster Rocha ✉ [Email Católica de Santa Catarina | gabriel04.rocha@catolicasc.edu.br]

Nome do Orientador 📧 [Católica de Santa Catarina | orientador@catolicasc.edu.br]

✉ *Curso de Engenharia de Software, Centro Universitário – Católica de Santa Catarina, Jaraguá do Sul, SC, Brasil.*

1 Introdução

O cenário de inadimplência no Brasil apresenta desafios estruturais significativos para empresas de todos os portes. Segundo dados recentes, dezenas de milhões de brasileiros encontram-se em situação de inadimplência, o que impacta diretamente o fluxo de caixa das organizações e eleva os custos operacionais associados à recuperação de crédito [1]. Nesse contexto, os processos tradicionais de cobrança — baseados em ligações manuais, envio de correspondências e negociações presenciais — revelam-se cada vez mais insuficientes diante do volume crescente de devedores e da necessidade de abordagens personalizadas e tempestivas [2].

Paralelamente, os avanços recentes em Inteligência Artificial (IA) têm proporcionado novas possibilidades para a automação de processos complexos que envolvem linguagem natural e tomada de decisão. Entre as tecnologias emergentes, destacam-se os *Large Language Models* (LLMs), modelos de linguagem de grande escala capazes de compreender e gerar texto em linguagem natural com elevado grau de coerência e adequação contextual [3]. Complementarmente, a técnica de *Retrieval-Augmented Generation* (RAG) permite que esses modelos consultem bases de conhecimento externas antes de formular uma resposta, reduzindo alucinações e aumentando a precisão das informações fornecidas [4]. Além disso, abordagens de *Machine Learning* (ML) possibilitam a construção de modelos preditivos que identificam padrões em dados históricos para antecipar comportamentos futuros, como a propensão de um cliente a quitar ou não uma dívida [5].

No domínio de sistemas inteligentes, o paradigma de *agentes autônomos* e *sistemas multiagentes* tem ganhado relevância prática. Diferentemente de aplicações conversacionais passivas, agentes autônomos são capazes de planejar, executar ações e interagir com ferramentas externas de forma independente, orientados por objetivos definidos [6]. Essa capacidade é particularmente promissora para processos de cobrança, nos quais a abordagem proativa — isto é, a identificação e o contato com clientes inadimplentes sem intervenção humana — pode aumentar significativamente as taxas de recuperação de crédito.

Adicionalmente, a integração de serviços de processamento de voz amplia o espectro de canais de comunicação disponíveis para sistemas automatizados. Tecnologias de transcrição automática de fala, como o Whisper [7] e o Google Speech-to-Text [8], permitem que mensagens de áudio — comuns em plataformas de mensageria como o WhatsApp — sejam convertidas em texto e interpretadas por agentes in-

teligentes. De forma complementar, plataformas de telefonia programável, como Twilio e Vonage, viabilizam a realização de chamadas telefônicas automatizadas, com transcrição em tempo real da conversa para alimentar o agente durante a interação [9].

Diante desse panorama, o presente trabalho propõe o desenvolvimento de um sistema multiagente inteligente de cobrança que integra LLMs, RAG, modelos preditivos de *Machine Learning* e serviços de voz. O sistema opera em dois modos complementares: (i) um modo **responsivo**, acionado quando o cliente entra em contato para resolver pendências financeiras, no qual o agente utiliza RAG para responder dúvidas com base em documentação interna; e (ii) um modo **ativo (proativo)**, no qual o próprio sistema identifica documentos vencidos ou clientes inadimplentes e inicia a abordagem de cobrança de forma autônoma, inclusive por meio de chamadas telefônicas automatizadas. Além disso, um módulo preditivo classifica clientes por propensão ao pagamento e antecipa situações de inadimplência futura, possibilitando ações de cobrança preventiva.

2 Problema de Pesquisa

Os métodos convencionais de cobrança enfrentam limitações relacionadas à escalabilidade, à personalização do contato e à tempestividade da abordagem. Operadores humanos possuem capacidade limitada de atendimento simultâneo, e a ausência de priorização inteligente frequentemente resulta em esforços direcionados a clientes com baixa probabilidade de pagamento, enquanto devedores com maior propensão à quitação permanecem sem contato adequado [10]. Além disso, a comunicação predominantemente textual dos sistemas automatizados existentes desconsidera canais amplamente utilizados pelos clientes, como mensagens de voz e chamadas telefônicas.

Nesse contexto, formula-se a seguinte pergunta de pesquisa:

Em que medida um sistema multiagente inteligente, baseado em LLMs com RAG e modelos preditivos de Machine Learning, integrado a serviços de transcrição de áudio e telefonia programável, é capaz de automatizar o processo de cobrança — tanto de forma responsiva quanto proativa — e contribuir para o aumento da eficiência na recuperação de crédito em comparação com abordagens convencionais?

3 Hipótese

A hipótese central deste trabalho é que um sistema multiagente inteligente, ao combinar (i) agentes conversacionais baseados em LLMs com RAG para atendimento responsivo, (ii) agentes autônomos para abordagem proativa de cobrança por múltiplos canais — incluindo texto, áudio e chamadas telefônicas — e (iii) um módulo preditivo de *Machine Learning* para classificação de inadimplentes e previsão de inadimplência futura, é capaz de reduzir o tempo médio de recuperação de crédito e aumentar a taxa de resolução de pendências financeiras, quando comparado a processos de cobrança manuais ou parcialmente automatizados sem inteligência preditiva.

Essa hipótese fundamenta-se na premissa de que a priorização inteligente de contatos, aliada à capacidade de operar simultaneamente em múltiplos canais de comunicação e de personalizar a abordagem conforme o perfil do devedor, potencializa a eficácia do processo de cobrança [11].

4 Objetivos

4.1 Objetivo Geral

Desenvolver e avaliar um sistema multiagente inteligente de cobrança que integre modelos de linguagem de grande escala com *Retrieval-Augmented Generation*, agentes autônomos, modelos preditivos de *Machine Learning* e serviços de processamento de voz, operando de forma responsiva e proativa para automatizar o ciclo de recuperação de crédito em múltiplos canais de comunicação.

4.2 Objetivos Específicos

1. **Analisar** os processos tradicionais de cobrança e os requisitos funcionais e não funcionais necessários para a automação inteligente do ciclo de recuperação de crédito, considerando aspectos legais e operacionais pertinentes.
2. **Projetar** a arquitetura do sistema multiagente, definindo os papéis, as responsabilidades e os mecanismos de coordenação entre os agentes responsivo e ativo, bem como a integração com serviços externos de transcrição de áudio e telefonia programável.
3. **Implementar** o módulo responsivo do sistema, baseado em LLM com RAG, capaz de interpretar mensagens textuais e transcrições de áudio de clientes e fornecer respostas contextualizadas a partir de documentação interna.
4. **Implementar** o módulo ativo (proativo), composto por agentes autônomos capazes de identificar documentos vencidos, iniciar abordagens de cobrança por canais textuais e realizar chamadas telefônicas automatizadas com transcrição em tempo real.
5. **Desenvolver** o módulo preditivo de *Machine Learning* para classificar clientes inadimplentes por propensão ao pagamento e prever a probabilidade de inadimplência futura em documentos ainda não vencidos, possibilitando a priorização e a cobrança preventiva.
6. **Avaliar** o sistema proposto por meio de experimentos controlados, métricas de desempenho dos modelos preditivos (acurácia, precisão, revocação e *F1-score*) e indicadores operacionais de cobrança (taxa de recupera-

ção, tempo médio de resolução), comparando os resultados com *baselines* representativos de processos convencionais.

5 Proposta de Estruturação do Texto

A versão final do TCC será organizada nos capítulos descritos a seguir.

5.1 Capítulo 1 — Introdução

Apresentará a contextualização do cenário de inadimplência no Brasil, a motivação para a automação inteligente de processos de cobrança, o problema de pesquisa, a hipótese, os objetivos geral e específicos, a justificativa do trabalho e a organização do documento.

5.2 Capítulo 2 — Fundamentação Teórica

Abordará os conceitos fundamentais que sustentam o trabalho, organizados nos seguintes eixos temáticos: (i) processos de cobrança e recuperação de crédito; (ii) *Large Language Models* e técnicas de *prompting*; (iii) *Retrieval-Augmented Generation* (RAG) e bases de conhecimento vetoriais; (iv) agentes autônomos e sistemas multiagentes; (v) modelos de *Machine Learning* para classificação e predição; (vi) serviços de transcrição automática de fala e telefonia programável; e (vii) trabalhos relacionados que aplicam IA a processos de cobrança ou atendimento automatizado.

5.3 Capítulo 3 — Metodologia

Descreverá a abordagem metodológica adotada, incluindo a classificação da pesquisa, as etapas de desenvolvimento do sistema (levantamento de requisitos, projeto arquitetural, implementação e testes), as fontes de dados utilizadas para treinamento dos modelos preditivos, os critérios de avaliação e as métricas definidas para validação da hipótese.

5.4 Capítulo 4 — Desenvolvimento do Sistema

Detalhará a arquitetura do sistema multiagente, as decisões de projeto, as tecnologias empregadas e a implementação de cada módulo: (i) módulo responsivo com LLM e RAG; (ii) módulo ativo com agentes autônomos e integração a canais de voz; e (iii) módulo preditivo de *Machine Learning*. Serão apresentados diagramas de arquitetura, fluxos de interação e trechos relevantes de código.

5.5 Capítulo 5 — Experimentos e Resultados

Apresentará os experimentos realizados para validação do sistema, incluindo a descrição dos cenários de teste, os conjuntos de dados utilizados, as métricas coletadas e a análise comparativa dos resultados obtidos em relação aos *baselines* definidos. Serão discutidas as limitações identificadas e as implicações práticas dos achados.

5.6 Capítulo 6 — Considerações Finais

Sintetizará as contribuições do trabalho, o grau de atendimento dos objetivos propostos, as limitações encontradas e as sugestões de trabalhos futuros, incluindo possíveis extensões do sistema e novas direções de pesquisa.

Referências

- [1] Serasa Experian. Mapa da Inadimplência e Negociação de Dívidas no Brasil. Disponível em: <https://www.serasa.com.br/limpa-nome-online/blog/mapa-da-inadimplencia-e-renogociacao-de-dividas-no-brasil/>. Acesso em março de 2026.
- [2] Pesquisa de Endividamento e Inadimplência do Consumidor (Peic) – agosto de 2025. Confederação Nacional do Comércio de Bens, Serviços e Turismo (CNC), 2026. Disponível em: https://portaldocomercio.org.br/publicacoes_posts/pesquisa-de-endividamento-e-inadimplencia-do-consumidor-peic-agosto-de-2025/. Acesso em março de 2026.
- [3] Brown, T. B. Language models are few-shot learners. Disponível em: <https://doi.org/10.48550/arXiv.2005.14165>. Acesso em março de 2026.
- [4] Lewis, P. Retrieval-augmented generation for knowledge-intensive NLP tasks. Disponível em: <https://doi.org/10.48550/arXiv.2005.11401>. Acesso em março de 2026.
- [5] Hastie, T.; Tibshirani, R.; Friedman, J. *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. 2. ed. New York: Springer, 2009.
- [6] Wang, L. et al. A survey on large language model based autonomous agents. *Frontiers of Computer Science*, v. 18, n. 6, 2024. Disponível em: <https://doi.org/10.48550/arXiv.2308.11432>. Acesso em março de 2026.
- [7] Radford, A. Robust speech recognition via large-scale weak supervision. Disponível em: <https://doi.org/10.48550/arXiv.2212.04356>. Acesso em março de 2026.
- [8] Google Cloud. Speech-to-Text documentation. Disponível em: <https://cloud.google.com/speech-to-text/docs>. Acesso em março de 2026.
- [9] Twilio Inc. Programmable Voice documentation. Disponível em: <https://www.twilio.com/docs/voice>. Acesso em março de 2026.
- [10] Thomas, L. C. *Consumer Credit Models: Pricing, Profit and Portfolios*. Oxford: Oxford University Press, 2009.
- [11] Lessmann, S. et al. Benchmarking state-of-the-art classification algorithms for credit scoring: An update of research. *European Journal of Operational Research*, v. 247, n. 1, p. 124–136, 2015.