

PROPOSTA DE PORTFÓLIO

Sistema Multiagente Inteligente de Cobrança com LLM, RAG e Machine Learning

Intelligent Multi-Agent Collection System with LLM, RAG and Machine Learning

Gabriel Forster Rocha [Centro Universitário Católica de Santa Catarina | gabriel04.rocha@catolicasc.edu.br]

Andrei Carniel [Centro Universitário Católica de Santa Catarina | andrei.carniel@catolicasc.org.br]

Curso de Engenharia de Software, Centro Universitário — Católica de Santa Catarina, Jaraguá do Sul, SC, Brasil.

Resumo. Este trabalho propõe o desenvolvimento de um sistema multiagente inteligente de cobrança que integra modelos de linguagem de grande escala (*Large Language Models* — LLMs), geração aumentada por recuperação (*Retrieval-Augmented Generation* — RAG), modelos preditivos de *Machine Learning* e serviços de processamento de voz. O sistema opera em dois modos complementares: (i) um modo responsivo, no qual o agente utiliza RAG para responder dúvidas de clientes com base em documentação interna; e (ii) um modo ativo (proativo), no qual o próprio sistema identifica documentos vencidos ou clientes inadimplentes e inicia a abordagem de cobrança de forma autônoma, inclusive por chamadas telefônicas automatizadas. Um módulo preditivo classifica clientes por propensão ao pagamento e antecipa a inadimplência futura, possibilitando cobrança preventiva. Diante de um cenário de inadimplência que afeta dezenas de milhões de consumidores no Brasil, os processos tradicionais de cobrança apresentam limitações de escalabilidade, personalização e tempestividade. A combinação de agentes autônomos, modelos de linguagem e aprendizado de máquina representa, portanto, uma oportunidade relevante para automatizar e otimizar o ciclo de recuperação de crédito em múltiplos canais. Este documento apresenta a proposta de portfólio, descrevendo o problema de pesquisa, a hipótese, os objetivos, a inovação, a arquitetura e as tecnologias previstas, os resultados esperados e o cronograma de desenvolvimento.

Abstract. This work proposes the development of an intelligent multi-agent collection system that integrates Large Language Models (LLMs), Retrieval-Augmented Generation (RAG), predictive Machine Learning models, and voice processing services. The system operates in two complementary modes: (i) a responsive mode, in which the agent uses RAG to answer customer questions based on internal documentation; and (ii) an active (proactive) mode, in which the system itself identifies overdue documents or delinquent customers and autonomously initiates the collection approach, including automated phone calls. A predictive module classifies customers by their propensity to pay and anticipates future delinquency, enabling preventive collection. Given a delinquency scenario affecting tens of millions of consumers in Brazil, traditional collection processes show limitations in scalability, personalization, and timeliness. Combining autonomous agents, language models, and machine learning thus represents a relevant opportunity to automate and optimize the credit recovery cycle across multiple channels. This document presents the portfolio proposal, describing the research problem, the hypothesis, the objectives, the innovation, the planned architecture and technologies, the expected results, and the development schedule.

Palavras-chave: Sistema multiagente, Inteligência Artificial, Cobrança automatizada, RAG, Machine Learning, LLM

Keywords: Multi-agent system, Artificial Intelligence, Automated collection, RAG, Machine Learning, LLM

1 Introdução

O cenário de inadimplência no Brasil apresenta desafios estruturais significativos para empresas de todos os portes. Dezenas de milhões de brasileiros encontram-se em situação de inadimplência, o que impacta diretamente o fluxo de caixa das organizações e eleva os custos operacionais associados à recuperação de crédito [?]. Nesse contexto, os processos tradicionais de cobrança — baseados em ligações manuais, envio de correspondências e negociações presenciais — revelam-se cada vez mais insuficientes diante do volume crescente de devedores e da necessidade de abordagens personalizadas e tempestivas [?].

Paralelamente, os avanços recentes em Inteligência Artificial (IA) têm proporcionado novas possibilidades para a automação de processos complexos que envolvem linguagem natural e tomada de decisão. Destacam-se os *Large Language Models* (LLMs), capazes de compreender e gerar texto com elevado grau de coerência e adequação contextual [?]. Complementarmente, a técnica de *Retrieval-Augmented Generation* (RAG) permite que esses modelos consultem

bases de conhecimento externas antes de formular uma resposta, reduzindo alucinações e aumentando a precisão das informações fornecidas [?]. Além disso, abordagens de *Machine Learning* (ML) possibilitam a construção de modelos preditivos que identificam padrões em dados históricos para antecipar comportamentos futuros, como a propensão de um cliente a quitar ou não uma dívida [?]. No domínio de sistemas inteligentes, o paradigma de *agentes autônomos* e *sistemas multiagentes* tem ganhado relevância prática: diferentemente de aplicações conversacionais passivas, agentes autônomos planejam, executam ações e interagem com ferramentas externas de forma independente, orientados por objetivos [?]. A isso soma-se a integração de serviços de voz: tecnologias de transcrição automática de fala, como o Whisper [?] e o Google Speech-to-Text [?], e plataformas de telefonia programável, como Twilio [?], ampliam os canais de comunicação disponíveis para sistemas automatizados.

Diante desse panorama, o presente trabalho propõe um sistema multiagente inteligente de cobrança que integra LLMs, RAG, modelos preditivos de ML e serviços de voz,

operando de forma responsiva e proativa para automatizar o ciclo de recuperação de crédito em múltiplos canais.

A relevância do trabalho decorre do impacto econômico da inadimplência e da lacuna observada nas soluções existentes: ferramentas comerciais e acadêmicas atacam aspectos isolados do problema — ou a previsão de risco, ou a automação por voz, ou o atendimento conversacional — mas não integram, em um único fluxo, inteligência preditiva, recuperação de conhecimento e operação multicanal. Ao reunir essas capacidades, a proposta busca tanto reduzir o custo operacional da cobrança quanto qualificar o contato com o cliente, direcionando o esforço humano para os casos de maior complexidade.

Problema de Pesquisa: os métodos convencionais de cobrança enfrentam limitações de escalabilidade, personalização e tempestividade. Operadores humanos possuem capacidade limitada de atendimento simultâneo, e a ausência de priorização inteligente frequentemente direciona esforços a clientes com baixa probabilidade de pagamento, enquanto devedores com maior propensão à quitação permanecem sem contato adequado [?]. Formula-se, assim, a pergunta: *em que medida um sistema multiagente inteligente, baseado em LLMs com RAG e modelos preditivos de Machine Learning, integrado a serviços de transcrição de áudio e telefonia programável, é capaz de automatizar o processo de cobrança — tanto de forma responsiva quanto proativa — e contribuir para o aumento da eficiência na recuperação de crédito em comparação com abordagens convencionais?*

Hipótese: um sistema multiagente que combine (i) agentes conversacionais baseados em LLMs com RAG para atendimento responsivo, (ii) agentes autônomos para abordagem proativa por múltiplos canais (texto, áudio e chamadas telefônicas) e (iii) um módulo preditivo de ML para classificação de inadimplentes e previsão de inadimplência futura é capaz de reduzir o tempo médio de recuperação de crédito e aumentar a taxa de resolução de pendências financeiras, quando comparado a processos manuais ou parcialmente automatizados sem inteligência preditiva [?].

Objetivos: o objetivo geral é desenvolver e avaliar um sistema multiagente inteligente de cobrança que integre LLMs com RAG, agentes autônomos, modelos preditivos de ML e serviços de voz, operando de forma responsiva e proativa. Como objetivos específicos pretende-se: (a) analisar os processos tradicionais de cobrança e levantar requisitos, considerando aspectos legais e operacionais; (b) projetar a arquitetura multiagente e os mecanismos de coordenação entre os agentes; (c) implementar o módulo responsivo com LLM e RAG; (d) implementar o módulo ativo com agentes autônomos e integração a canais de voz; (e) desenvolver o módulo preditivo de ML para classificação e previsão de inadimplência; e (f) avaliar o sistema por meio de experimentos controlados, com métricas preditivas e indicadores operacionais comparados a *baselines*.

Estruturação do Texto: a Seção 2 discute os trabalhos relacionados; a Seção 3 apresenta a proposta, a inovação e a arquitetura e tecnologias; a Seção 4 descreve os resultados esperados; a Seção 5 traz discussões e conclusões; e o Apêndice (Seção 6) reúne a tabela comparativa e o cronograma de desenvolvimento.

2 Trabalhos Relacionados

A literatura e o mercado oferecem contribuições parciais ao problema abordado. No eixo acadêmico, [?] apresentam uma revisão sistemática sobre agentes autônomos baseados em LLMs, fundamentando o paradigma multiagente adotado neste trabalho, embora sem foco em cobrança. [?] aplica modelos de *Machine Learning* e *Deep Learning* à tarefa de *credit scoring*, evidenciando o potencial preditivo em crédito, porém sem componente conversacional ou multicanal. Mais próximo da proposta, o sistema MASCA [?] combina múltiplos agentes baseados em LLMs para avaliação de crédito, mas não trata da execução da cobrança nem da operação por voz.

Entre as soluções comerciais, o HighRadius [?] é uma plataforma de automação de cobrança apoiada em IA e ML voltada predominantemente a canais textuais, enquanto Skit.ai [?] e Tovie AI [?] oferecem cobrança automatizada por voz, integrando LLMs, telefonia programável e transcrição automática de fala. Nenhuma dessas soluções, contudo, reúne simultaneamente RAG, arquitetura multiagente, operação multicanal (texto e voz) e cobrança preventiva baseada em previsão de inadimplência futura. A análise comparativa detalhada, com 12 critérios, é apresentada na Tabela 2 (Apêndice, Seção 6).

3 Metodologia

A pesquisa é de natureza aplicada, com abordagem experimental e desenvolvimento incremental, organizado em quatro etapas: (i) levantamento de requisitos funcionais e não funcionais e análise do domínio, incluindo aspectos legais — Código de Defesa do Consumidor [?], LGPD [?] e regras do PROCON quanto a horário e frequência de contato; (ii) projeto da arquitetura multiagente; (iii) implementação dos módulos; e (iv) avaliação por experimentos controlados frente a *baselines* convencionais. As fontes de dados para os modelos preditivos compreendem o histórico de clientes e documentos financeiros (dados cadastrais, vencimentos, pagamentos, atrasos e acordos), anonimizados conforme a LGPD e divididos em treino, validação e teste (70/15/15) com estratificação e respeito à ordem temporal para evitar vazamento de dados. A base de conhecimento do RAG é composta por políticas internas, *scripts* de negociação, tabelas de parcelamento e FAQs, fragmentados em *chunks* e indexados em banco vetorial.

3.1 Proposta de Portfólio

Propõe-se um sistema organizado em três módulos que operam de forma coordenada sob um orquestrador central.

O **módulo responsivo** (LLM + RAG) é acionado quando o cliente entra em contato por texto ou áudio; mensagens de voz do WhatsApp são transcritas por um serviço de *speech-to-text* antes do processamento. O agente identifica a intenção do cliente — consulta de débito, segunda via, negociação/parcelamento, contestação ou confirmação de pagamento — e, por meio do *pipeline* RAG, recupera os fragmentos mais relevantes da base de conhecimento (busca por similaridade de cosseno sobre *embeddings*, seleção dos *top-k* trechos e *re-ranking* opcional). Esses trechos, somados aos dados do cliente e ao histórico da conversa, compõem o

prompt enviado ao LLM, que gera uma resposta ancorada exclusivamente na documentação interna. Critérios de escalação — pedido explícito do cliente, baixa confiança na intenção ou situação sensível — transferem o atendimento a um operador humano com o contexto preservado.

O **módulo ativo (proativo)** é composto por agentes autônomos que, periodicamente, consultam documentos vencidos e clientes sinalizados pelo módulo preditivo. Um motor de regras decide quando e como abordar cada cliente, respeitando horário permitido, frequência máxima de contato, *cooldown* após tentativas sem resposta e limite de tentativas. A abordagem segue um escalonamento progressivo de canais — por exemplo, lembrete por mensagem de texto, segundo lembrete, chamada telefônica automatizada e aviso final — com mensagens personalizadas pelo LLM a partir de *templates* adequados a cada estágio de atraso. As chamadas empregam transcrição em tempo real e síntese de voz para uma conversa interativa, e todo contato registra o status de entrega e respeita pedidos de *opt-out*.

O **módulo preditivo** (ML) realiza duas tarefas: classificar clientes por propensão ao pagamento, priorizando os contatos, e prever a inadimplência futura de documentos ainda não vencidos, viabilizando a cobrança preventiva. São avaliados algoritmos de complexidade crescente — regressão logística (*baseline*), Random Forest, *Gradient Boosting* (XGBoost/LightGBM) e redes neurais — sobre atributos derivados do histórico, como dias médios de atraso, taxa de inadimplência histórica, frequência de atrasos recentes, valor relativo da dívida e tendência de pagamento. O desbalanceamento de classes é tratado com reamostragem (SMOTE) ou ponderação, e a interpretabilidade é apoiada por importância de atributos e valores SHAP. O modelo selecionado é serializado e exposto por uma API de inferência que alimenta o *ranking* de prioridade consumido pelo módulo ativo. Os três módulos operam, assim, em dois modos complementares: *responsivo*, dirigido pelo cliente, e *proativo*, dirigido por agendamento e pelos sinais preditivos.

3.1.1 Inovação

O diferencial da proposta está na integração, em um único produto voltado à cobrança, de capacidades hoje disponíveis apenas de forma isolada nos trabalhos correlatos. Conforme detalhado na Tabela 2, a proposta é a única a reunir simultaneamente: (i) **RAG aplicado à cobrança**, garantindo respostas ancoradas na documentação interna e reduzindo alucinações; (ii) **arquitetura multiagente** coordenando atendimento responsivo e abordagem proativa; (iii) **operação multicanal** que combina texto, áudio e telefonia programável; e (iv) **cobrança preventiva preditiva**, antecipando a inadimplência antes do vencimento — critério (P11) não atendido por nenhum dos trabalhos comparados. Essa combinação permite priorizar contatos de forma inteligente e personalizar a abordagem conforme o perfil do devedor.

3.2 Arquitetura e tecnologias

A arquitetura, ilustrada na Figura 1, organiza-se em quatro camadas. Um **orquestrador central** coordena os agentes, gerencia filas e aplica regras de negócio, priorizando interações responsivas (cliente aguardando) sobre as proativas. Abaixo dele atuam os três agentes (responsivo, proativo e




Figura 1. Visão geral da arquitetura multiagente em quatro camadas.

Tabela 1. Pilha tecnológica prevista.

Componente	Tecnologia
Backend/API	Python + FastAPI (microserviços)
LLM	Claude / GPT-4
Embeddings	OpenAI / Sentence Transformers
Banco vetorial	Qdrant / pgvector
ML	Random Forest / XGBoost (scikit-learn)
Orquestração de agentes	LangGraph / LangChain
Fila / Dados	Redis / AWS SQS · PostgreSQL
STT / TTS	Whisper · ElevenLabs
Telefonia	Twilio / Vonage
Mensageria	WhatsApp Business API

preditivo), que se apoiam em uma **camada de serviços externos** (transcrição de fala, telefonia, mensageria e base vetorial) e em uma **camada de dados** (banco de dados, fila de mensagens e *logs* de auditoria). A comunicação entre agentes ocorre por eventos assíncronos.

A coordenação entre os agentes ocorre por meio de uma fila de mensagens e eventos assíncronos, com regras de prioridade que privilegiam interações responsivas (cliente aguardando) sobre as proativas, além de políticas de escalação para atendimento humano. Todas as decisões e interações dos agentes são registradas em *logs* de auditoria, atendendo a requisitos de rastreabilidade e de conformidade com a LGPD, incluindo a criptografia de dados pessoais em repouso.

A pilha tecnológica prevista é apresentada na Tabela 1. O *backend* adota Python com FastAPI em microserviços, separando a validação de entrada da inferência dos modelos. O módulo preditivo emprega Random Forest e *Gradient Boosting* (XGBoost) sobre *scikit-learn*, servidos por uma API de inferência dedicada. O RAG utiliza um banco vetorial (Qdrant ou *pgvector*) e os agentes são orquestrados com LangGraph/LangChain. Os serviços de voz combinam Whisper (transcrição) e ElevenLabs (síntese), integrados à telefonia programável (Twilio/Vonage) e à WhatsApp Business API.

4 Resultados Esperados

Esta seção descreve uma previsão dos resultados, sujeita a ajustes até o final do PAC 8. Para o módulo preditivo, espera-se atingir, no conjunto de teste, $F1\text{-score} \geq 0,75$, acurácia

$\geq 0,80$ e $AUC-ROC \geq 0,80$ tanto na classificação de propensão ao pagamento quanto na previsão de inadimplência futura, superando um *baseline* de regressão logística simples. Para o módulo responsivo, espera-se elevada fidelidade das respostas (ancoradas na base via RAG) e baixa taxa de alucinação, com tempo de resposta inferior a cinco segundos.

A qualidade do módulo responsivo será medida em duas dimensões: a do *retrieval* (precisão e revocação em *top-k*) e a das respostas geradas (relevância, fidelidade aos documentos, completude e taxa de alucinação), aferidas sobre um conjunto de perguntas de teste com respostas de referência.

No plano operacional, a hipótese será avaliada em um experimento controlado, comparando o sistema proposto a dois *baselines* — processo manual e processo semiautomatizado sem ML — por um período definido, com análise estatística dos indicadores quando o tamanho da amostra permitir. Esperam-se ganhos na **taxa de recuperação de crédito** e redução no **tempo médio de resolução** de pendências, além de maior **volume de atendimento simultâneo** (meta de pelo menos 100 interações concorrentes) a um custo por contato inferior ao do atendimento humano. A priorização preditiva e a cobrança preventiva devem antecipar ações e concentrar esforços nos contatos de maior retorno.

5 Discussões e Conclusões

A proposta enfrenta desafios relevantes. No plano legal, a cobrança automatizada deve observar o Código de Defesa do Consumidor [?] e a Lei Geral de Proteção de Dados [?], o que impõe restrições de horário, frequência de contato, consentimento para gravação e proteção de dados pessoais. No plano técnico, destacam-se a latência em chamadas de voz com transcrição em tempo real, o risco de alucinação do LLM — mitigado pelo RAG e por restrições de *prompt* — e o possível desbalanceamento de classes nos dados de inadimplência, que demandará técnicas como reamostragem ou ponderação de classes.

Um aspecto sensível é o equilíbrio entre automação e empatia: a cobrança lida com pessoas em situação financeira delicada, de modo que o tom das mensagens, a transparência sobre a natureza automatizada do atendimento e o respeito imediato a pedidos de interrupção de contato são requisitos tão importantes quanto o desempenho técnico. Decisões preditivas também exigem cuidado para não penalizar indevidamente determinados perfis de clientes, o que reforça a importância da interpretabilidade dos modelos.

A proposta resolve a limitação de escala e de priorização do processo manual, unificando atendimento responsivo, abordagem proativa multicanal e inteligência preditiva. Não se propõe, contudo, a substituir integralmente o operador humano: casos sensíveis e negociações fora dos parâmetros automáticos permanecem sujeitos a escalção. São limitações previstas a dependência de dados históricos de qualidade e os custos de APIs de LLM, voz e telefonia. Como trabalhos futuros, vislumbram-se a personalização de estratégias por segmento de cliente, o uso de aprendizado por reforço para otimizar políticas de contato e a expansão a novos canais. Conclui-se que a integração de LLMs com RAG, agentes autônomos, modelos preditivos e serviços de voz constitui um caminho promissor para automatizar e tornar mais efi-

ciente o ciclo de recuperação de crédito, hipótese a ser validada experimentalmente ao longo do PAC 8.

6 Apêndice

Este apêndice reúne a tabela comparativa de trabalhos relacionados (Tabela 2) e o cronograma de desenvolvimento em semanas, da data atual até o final do PAC 8 (Tabela 3).

Tabela 2. Tabela comparativa de trabalhos relacionados. Legenda: ✓ atende, ~ parcial, ✗ não atende; A1–A3 = artigos científicos, S1–S3 = soluções comerciais.

Critério	A1	A2	A3	S1	S2	S3	Prop.
	Wang et al. (2024)	Mestiri (2024)	MASCA — Jajoo et al. (2025)	HighRadius	Skit.ai	Tovie AI	Proposta do TCC
<i>Tecnologias de Inteligência Artificial</i>							
P1 — LLM (Modelo de Linguagem de Grande Escala)	✓	✗	✓	~	✓	✓	✓
P2 — RAG (Retrieval-Augmented Generation)	✗	✗	~	✗	✗	✗	✓
P3 — Modelos preditivos de Machine Learning	✗	✓	~	✓	~	~	✓
P4 — Arquitetura multiagente	✓	✗	✓	✗	✗	✗	✓
<i>Canais de Comunicação</i>							
P5 — Operação multicanal (texto + voz)	✗	✗	✗	✓	✓	✓	✓
P6 — Integração com telefonia programável	✗	✗	✗	✗	✓	✓	✓
P7 — Transcrição automática de fala (STT)	✗	✗	✗	✗	✓	✓	✓
<i>Estratégia de Cobrança</i>							
P8 — Abordagem proativa autônoma	~	✗	✗	✓	✓	✓	✓
P9 — Atendimento responsivo ao cliente	~	✗	✗	~	✓	✓	✓
P10 — Priorização inteligente de inadimplentes	✗	~	✓	✓	~	~	✓
P11 — Cobrança preventiva (inadimplência futura)	✗	✗	✗	~	✗	✗	✓
<i>Domínio de Aplicação</i>							
P12 — Foco específico em cobrança e recuperação de crédito	✗	~	✓	✓	✓	✓	✓
Pontuação total (máx. 12,0)	3,0	2,0	5,0	6,5	8,0	8,0	12,0
Cobertura dos requisitos (%)	25%	17%	42%	54%	67%	67%	100%

Tabela 3. Cronograma de desenvolvimento em semanas (jun. a dez. de 2026).

Semanas	Etapas
1–2	Requisitos e análise do domínio (LGPD/CDC)
3–5	Coleta e preparação de dados (EDA, <i>feature engineering</i>)
6–9	Módulo preditivo de ML (treino, avaliação, API)
8–11	Arquitetura multiagente e orquestrador
10–14	Módulo responsivo (RAG + LLM)
13–17	Módulo ativo/proativo (agentes, WhatsApp, regras)
16–19	Integração de voz (STT/TTS, telefonia)
19–22	Testes, experimentos e avaliação
22–24	Redação final e preparação da defesa